

Vorlesungsmitschrift

REDUZIERTE BASIS METHODEN

UNIVERSITÄT STUTTGART, SS15
Prof. Dr. Bernard Haasdonk

AUTOREN:
Stefan Simeonov
Frank Schneider

STAND:
17. Juni 2015

Inhaltsverzeichnis

1	Einleitung	2
1.1	Modellreduktion	3
2	Grundlagen	8
3	RB-Methoden für lineare koerzive Probleme	16
3.1	Primales RB-Problem	16
3.2	Fehleranalyse	19
3.3	Offline/Online-Zerlegung	30
3.4	Offline-/Online- Zerlegung für Fehlerschranken/Effektivitätsschranken . .	34
3.5	Basisgenerierung	41

1 Einleitung

Parameterabhängige Probleme

Beispiel 1.1 (Parameterabhängige PDE)

Sie $\Omega \subseteq \mathbb{R}^d$ polygonales Gebiet. Zu Parametervektor $\mu \in \mathcal{P} \subset \mathbb{R}^p$ aus einer Menge \mathcal{P} von „erlaubten“ Parametern ist eine Funktion (z. B. „Temperatur“) $u(\mu) : \Omega \rightarrow \mathbb{R}$, s. d.:

$$\begin{aligned} \nabla \cdot (\kappa(\mu) \nabla u) &= q(\mu) && \text{in } \Omega \\ u(\mu) &= 0 && \text{auf } \delta\Omega \end{aligned}$$

mit $\kappa(\mu) : \Omega \rightarrow \mathbb{R}$ (z. B. „Wärmeleitungskoeffizient“)

und $q(\mu) : \Omega \rightarrow \mathbb{R}$ (z. B. „Wärmequelle/-senke“)

$$\text{z. B. } q(x; \mu) := \begin{cases} 1 & \text{für } x \in \Omega_q \\ 0 & \text{sonst} \end{cases}$$

Weiter kann Ausgabe erwünscht, z. B. mittlere Temperatur

$$s(\mu) = \frac{1}{|\Omega_s|} \int u(x; \mu) dx$$




Abbildung 1: Beispiel Wärmeleitung mit Quelle Ω_q und Messbereich Ω_s
(aus B. Haasdonk, Reduzierte-Basis-Methoden, Skript zur Vorlesung SS 2011, Universität Stuttgart, IANS-Report 4/11, 2011.)

Beispiel 1.2 (Parametrisches stationäres System)

Zu Parameter $\mu \in \mathcal{P} \subseteq \mathbb{R}^p$ ist Zustandsvektor $u(\mu) \in \mathbb{R}^n$ und Ausgabe $s(\mu) \in \mathbb{R}^k$ gesucht, s. d.:

$$\begin{aligned} 0 &= A(\mu) \cdot u(\mu) + B(\mu)w(\mu) \\ s(\mu) &= l(\mu) \cdot u(\mu) \end{aligned}$$

mit parameterabhängigen Matrizen $A(\mu) \in \mathbb{R}^{n \times n}$, $B(\mu) \in \mathbb{R}^{n \times m}$, $C(\mu) \in \mathbb{R}^{k \times n}$ mit Eingabevektor $w \in \mathbb{R}^m$.

Schwache Formulierung in Hilberträumen

Sie X reeller Hilbertraum (reel, seperabel). Zu $\mu \in \mathcal{P}$ ist gesucht ein $u(\mu) \in X$ und $s(\mu) \in \mathbb{R}$

$$\begin{aligned} a(u(\mu), v; \mu) &= f(v; \mu) \\ s(\mu) &= l(u(\mu); \mu) \end{aligned} \quad \forall v \in X$$

Mit Bilinearform $a(\cdot, \cdot; \mu)$ und Linearform $f(\cdot; \mu)$, $l(\cdot; \mu)$. Beide Beispiele lassen sich so formulieren.

z. B. 1.1:

$$\begin{aligned} X &= H_0^1(\Omega) := \{f \in L^2(\Omega) \mid \frac{\partial}{\partial x_i} f \in L^2(\Omega), f|_{\partial\Omega} = 0\} \\ \underbrace{\int_{\Omega} \kappa(x; \mu) \nabla u(x; \mu) \cdot \nabla v(x) dx}_{a(u(\mu), v; \mu)} &= \underbrace{\int_{\Omega} q(x; \mu) \cdot v(x) dx}_{f(v; \mu)} \quad \forall v \in X \\ s(\mu) &= \frac{1}{|\Omega_s|} \int_{\Omega_s} u(x; \mu) =: l(u(\mu); \mu) \end{aligned}$$

Zu Bsp. 1.2 ($k = 1$, „single output“) $X = \mathbb{R}^n$

$$\begin{aligned} \underbrace{v^T A(\mu) u(\mu)}_{a(u(\mu), v; \mu)} &= \underbrace{-v^T B w}_{f(v; \mu)} \\ s(\mu) &:= \underbrace{C(\mu) u(\mu)}_{l(u(\mu); \mu)} \end{aligned}$$

In der Vorlesung werden weitere Verallgemeinerungen zu $a : X_1 \times X_2 \rightarrow \mathbb{R}$ mit $X_1 \neq X_2$, nichtlinear und instationäre Probleme behandelt.

1.1 Modellreduktion

Grundidee/Motivation

- $\mathcal{M} := \{u(\mu) \mid \mu \in \mathcal{P}\} \subset X$ für $\mathcal{P} \subseteq \mathbb{R}^p$ ist die durch μ parametrisierte Lösungsmanigfaltigkeit.
- X ist im allgemeinen ∞ -dimensional Sobolev-Raum) oder endlich- aber sehr hoch-dimensional (FEM, FV, FD-Raum). \mathcal{M} ist aber höchstens p -dimensional.
 \Rightarrow Motivation für Suche nach einem niedrigdimensionalen Teilraum $X_n \subseteq X$ zur Approximation von \mathcal{M} und einer Approximation $u_N(\mu) \approx u(\mu)$, $u_N(\mu) \in X_N$
- Insbesondere bei Reduzierten-Basis-Methoden (RB-Methoden):
 X_N durch Beispiellösungen erzeugt, sog. „Snapshots“
 $X_N \subseteq \text{span}\{u(\mu_1), \dots, u(\mu_n)\}$ für geeignete Parameterwerte $\mu_i \in \mathcal{P}$.
Ziel ist außerdem Fehlerkontrolle durch Schranken $\Delta_N(\mu)$:

$$\|u(\mu) - u_N(\mu)\| \leq \Delta_N(\mu)$$




Abbildung 2: Parametrisierte niedrigdimensionale Lösungsmenge
(aus dem Online-Skript von Prof. Dr. Haasdonk zu Reduzierte Basen 2015)

Illustration

Beispiel 1.3

Gesucht ist $u(\mu) \in C^2([0,1])$ mit

$$\begin{aligned} (1 + \mu)u'' &= 1 & \text{auf } (0,1) \\ u(0) &= u(1) = 1 \end{aligned}$$

Für $\mu \in [0,1] =: \mathcal{P} \subseteq \mathbb{R}$. Spezielle Lösungen („Snapshots“)

$$\begin{aligned} \mu = 0 &\Rightarrow u_0(x) = u(x; \mu = 0) = \frac{1}{2}x - \frac{1}{2}x + 1 \\ \mu = 1 &\Rightarrow u_1(x) = u(x; \mu = 1) = \frac{1}{4}x - \frac{1}{4}x + 1 \end{aligned}$$

RB-Raum: $X_N := \text{span}(u_0, u_1)$ Reduzierte Lösung gegeben durch

$$\begin{aligned} u_N(\mu) &:= \alpha_0(\mu)u_0 + \alpha_1(\mu)u_1 \\ \alpha_0(\mu) &= \frac{2}{\mu + 1} - 1; \quad \alpha_1(\mu) = 2 - \frac{2}{\mu + 1} \end{aligned}$$

Diese erfüllt

$$\|u_N(\mu) - u(\mu)\|_\infty = \sup_\mu \|u(\mu) - u_N(\mu)\| = 0$$

ist somit exakt. \mathcal{M} ist enthalten in 2-dimensionalem Unterraum X_N : Genauer $\alpha_0 + \alpha_1 = 1, 0 \leq \alpha_0, \alpha_1 \leq 1$, also ist \mathcal{M} Menge der Konvexkombinationen von u_0, u_1 .

Begriffe

- Eine PDE ist ein *analytisches* Modell, welches die *exakte Lösung* $u(\mu) \in X$ in einem typischerweise ∞ -dimensionalen Funktionenraum X charakterisiert.
- Ein *detailliertes Modell* (auch *hochdimensionales Modell*) ist ein Berechnungsverfahren oder charakterisiert eine Approximation $u(\mu) \in X$ in hochdimensionalen Raum mit sehr allgemeinen Approximationseigenschaften. (z.B. FEM/FV/FD, $\dim X = 10^3 - 10^8$). In dieser Vorlesung kann $u(\mu)$ sowohl eine analytische als auch eine detaillierte Lösung darstellen.
- Ein *reduziertes* Modell ist ein Berechnungsverfahren bzw. eine Charakterisierung einer reduzierten Lösung $u_N(u)$ in einem sehr problemangepassten Raum X_N ($\dim X_N = 1 - 10^3$).
- *Modellreduktion* beschäftigt sich mit Methoden der Erzeugung reduzierter Modelle und Untersuchung ihrer Eigenschaften
- Modellreduktion ist ein modernes Gebiet der angewandten Mathematik und Ingenieurwissenschaften (Schwerpunkt in SimTech PN3, MOR-Seminar)

Anwendungen für parametrische reduzierte Modelle

„Kleinere“ Modelle stellen geringere Anforderungen an Rechenzeit und Speicher, daher Einsatz in:

- „multi-query“-Kontext, d. h. Vielfachanfragen unter Parametervariation: Parameterstudien, Design, Parameteridentifikation, Inverse Probleme, Optimierung, statistische Analyse
- Multi-skalen-Modelle (reduzierte Mikrolöser)
- „real-time“-Kontext, d. h. Anwendungen mit schneller Simulationsantwort: Interaktive Benutzeroberfläche, Web-Formulare, Echtzeitsteuerung von Prozessen
- „cool-computing“-Kontext, d. h. Simulation auf „einfacher“ Hardware: elektronische Regler, Smartphones, Ubiquitous Computing

Demonstration

demo_thermalblock.m aus RBmatlab, Smartphone App JaRMoS

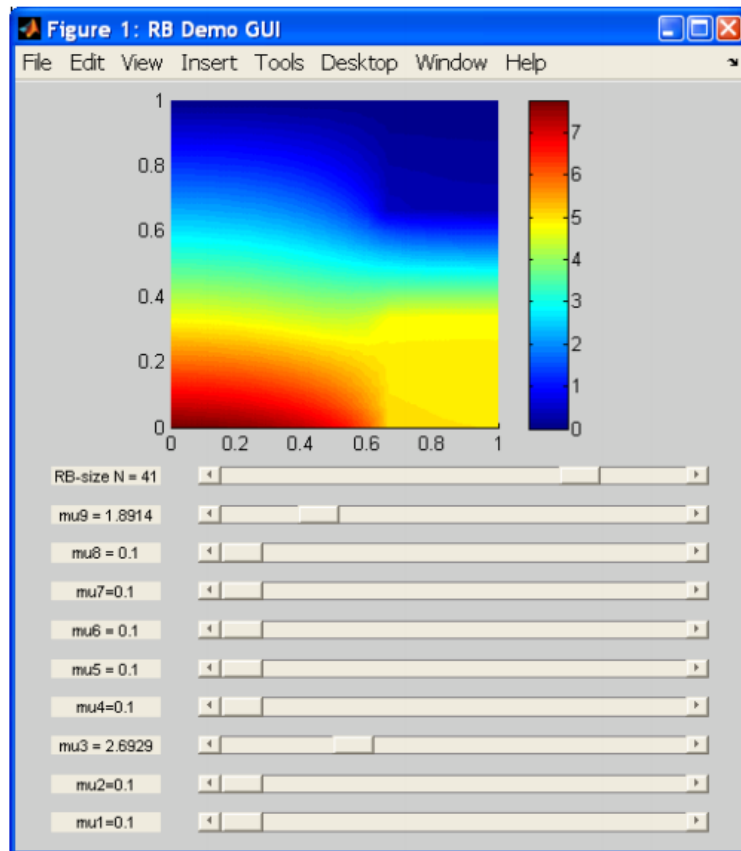


Abbildung 3: Beispiel des Thermischen Blocks aus `demo_thermalblock.m`
 (aus B. Haasdonk, Reduzierte-Basis-Methoden, Skript zur Vorlesung SS 2011, Universität
 Stuttgart, IANS-Report 4/11, 2011.)

Offline/Online Zerlegung

Typischerweise wird eine Verechnungsintensive Generierung des reduzierten Modells akzeptiert, sog. *Offline-Phase*. Dies ermöglicht schnelle Anwendbarkeit des reduzierten Modells in der *Online-Phase*. Offline-Kosten werden gerechtfertigt durch Amortisierung im multi-query-Kontext, d. h. Laufzeitgewinn bei genügend großer Anzahl an Online-Simulationen

multi-query mit detailliertem Modell:



multi-query mit reduziertem Modell:




Abbildung 4: Laufzeitvergleich eines detaillierten mit einem reduzierten Modell
(aus dem Online-Skript von Prof. Dr. Haasdonk zu Reduzierte Basen 2015)

Zentrale Fragen

- Reduzierte Basis: Wie kann ein möglichst kompakter Teilraum konstruiert werden? Können solche Verfahren *beweisbar* gut sein?
- Reduziertes Modell: Wie kann eine Lösung $u_N(\mu) \in X_N$ bestimmt werden
- Berechnungs-Effizienz: Wie kann $u_N(\mu)$ *schnell* berechnet werden?
- Stabilität: Wie kann Stabilität des reduzierten Modells garantiert werden bei wachsendem $N := \dim X_N$?
- Fehlerschätzer: Kann der Fehler des reduzierten zum detaillierten oder analytischen Modells beschränkt werden? Sind die Fehlerschätzer schnell berechenbar?
- Effektivität der Fehlerschätzer: Kann garantiert werden, dass der Schätzer den Fehler nicht zu pessimistisch überschätzt?
- Für welche Problemklassen kann ein RB-Ansatz funktionieren, für welche nicht?

Vorläufige Gliederung

- 1 Einleitung
- 2 Grundlagen
- 3 RB Verfahren für lineare koerzive Probleme
- 4 Allgemeinere lineare Probleme
- 5 Nichtlineare Probleme
- 6 Instationäre Probleme
- 7 Weiterführende Aspekte

2 Grundlagen

Im Folgenden sei X (oder X_1, X_2) stets reeller Hilbertraum mit Skalarprodukt $\langle \cdot, \cdot \rangle_X$, Norm $\| \cdot \|_X$ und Dualraum X' . Subskript wird weggelassen falls keine Verwechslungsgefahr besteht.

Definition 2.1 (Parametrische Formen)

Sei $\mathcal{P} \subset \mathbb{R}^p$ beschränkte Parametermenge. Dann nennen wir

- i) $l : X \times \mathcal{P} \rightarrow \mathbb{R}$ *parametrische stetige Linearform* falls $\forall \mu \in \mathcal{P}$:

$$l(\cdot; \mu) \in X'$$

- ii) $a : X_1 \times X_2 \times \mathcal{P} \rightarrow \mathbb{R}$ eine *parametrische stetige* (symmetrische) *Bilinearform*, falls für alle $\mu \in \mathcal{P}$

$$a(\cdot, \cdot; \mu) : X_1 \times X_2 \rightarrow \mathbb{R} \quad \text{ist bilinear und stetig (symmetrisch)}$$

Wir bezeichnen die Stetigkeitskonstante mit

$$\gamma(\mu) := \sup_{u \in X_1} \sup_{v \in X_2} \frac{a(u, v; \mu)}{\|u\|_{X_1} \|v\|_{X_2}}$$

Falls $X_1 = X_2 =: X$ und $a(\cdot, \cdot; \mu)$ ist koerziv für alle $\mu \in \mathcal{P}$, so ist $a(\cdot, \cdot; \cdot)$ *parametrisch koerziv* und wir bezeichnen die Koerzitivitätskonstante mit

$$\alpha(\mu) := \inf_{u \in X} \frac{a(u, u; \mu)}{\|u\|^2}$$

Bemerkung. Eine parametrische stetige Bi-/Linearform ist nicht unbedingt stetig bzgl. μ . Beispiel: $X = \mathbb{R}$, $\mathcal{P} = [0, 1]$, $l : X \times \mathcal{P} \rightarrow \mathbb{R}$ definiert durch

$$l(x; \mu) := \begin{cases} x & \text{falls } \mu < \frac{1}{2} \\ \frac{1}{2}x & \text{sonst} \end{cases}$$

Definition 2.2 (Parametrische Beschränktheit / Lipschitz-Stetigkeit / Koerzitivität)

Wir nennen

- i) eine parametrische stetige Linearform l bzw. Bilinearform a *gleichmäßig beschränkt* bzgl. μ falls ex. $\bar{\gamma}_l, \bar{\gamma} < \infty$ mit

$$\sup_{\mu \in \mathcal{P}} \|l(\cdot; \mu)\|_{X'} \leq \bar{\gamma}_l \quad \text{bzw.} \quad \sup_{\mu \in \mathcal{P}} \gamma(\mu) \leq \bar{\gamma}$$

- ii) a *gleichmäßig koerziv* bzgl. μ falls ex. $\bar{\alpha} > 0$ mit

$$\inf_{\mu \in \mathcal{P}} \alpha(\mu) \geq \bar{\alpha}$$

iii) l bzw. a *Lipschitz-stetig* bzgl. μ falls ex. L_l bzw. $L_a \in \mathbb{R}^+$, sodass $\forall \mu_1, \mu_2 \in \mathcal{P}$ gilt

$$|l(u; \mu_1) - l(u; \mu_2)| \leq L_l \|u\| \|\mu_1 - \mu_2\| \quad \forall u \in X$$

bzw.

$$|a(u, v; \mu_1) - a(u, v; \mu_2)| \leq L_a \|u\| \|v\| \|\mu_1 - \mu_2\| \quad \forall u \in X_1, v \in X_2$$

Definition 2.3 (Sensitivitätsableitung)

Sei $\mu_0 \in \mathcal{U} \subset \mathcal{P}$ in Umgebung \mathcal{U} von μ_0 . Wir nennen $f : \mathcal{U} \rightarrow X$ (Frechet)-differenzierbar in μ_0 , falls ex. ein $Df(\mu_0) \in L(\mathbb{R}^p, X)$ mit

$$\lim_{h \rightarrow 0} \frac{\|f(\mu_0 + h) - f(\mu_0) - Df(\mu_0)h\|}{\|h\|} = 0$$

Falls f in jedem $\mu \in \mathcal{U}$ diffbar, dann existieren insbesondere partielle Ableitungen

$$\frac{\partial}{\partial \mu_i} f(\cdot) := Df(\cdot) e_i : \mathcal{U} \rightarrow X$$

für $e_i \in \mathbb{R}^p$ Einheitsvektor $i = 1, \dots, p$. Falls diese wiederum diffbar in \mathcal{U} bezeichnet allgemein

$$\partial_\sigma f(\cdot) := \frac{\partial^{|\sigma|}}{\partial \mu_1^{\sigma_1} \dots \partial \mu_p^{\sigma_p}} f(\cdot) : \mathcal{U} \rightarrow X$$

die Sensitivitätsableitung der Ordnung $|\sigma| := \sum_{i=1}^p \sigma_i$ für Multiindex $\sigma = (\sigma_i)_{i=1}^p \in \mathbb{N}_0^p$.

Bemerkung. Diese Ableitungen werden später insbesondere bei parameterabhängigen Lösungen $u(x; \mu)$ verwendet:

$u : \Omega \times \mathcal{P} \rightarrow \mathbb{R}$ mit $u(\cdot; \mu) \in X$ kann auch als

$u : \mathcal{P} \rightarrow X$ aufgefasst werden mit Sensitivitätsableitungen

$\partial_\sigma u : \mathcal{P} \rightarrow X$, d.h. $\partial_\sigma u(\cdot; \mu) \in X \quad \forall \mu \in \mathcal{P}$ und insbesondere

$\partial_\sigma u : \Omega \times \mathcal{P} \rightarrow \mathbb{R}$, d.h. ∂_σ sind wieder Funktionen auf Ω

Definition 2.4 (Separierbare Parameterabhängigkeit)

- i) Eine Funktion $v : \mathcal{P} \rightarrow X$ nennen wir *separierbar parametrisch*, falls existieren Komponenten $v^q \in X$ und Koeffizientenfunktionen $\Theta_v^q : \mathcal{P} \rightarrow \mathbb{R}$ für $q = 1, \dots, Q_v$ mit

$$v(\mu) = \sum_{q=1}^{Q_v} \Theta_v^q(\mu) v^q$$

- ii) Eine parametrische stetige Linearform $l : X \times \mathcal{P} \rightarrow \mathbb{R}$ bzw. Bilinearform $a : X_1 \times X_2 \times \mathcal{P} \rightarrow \mathbb{R}$ ist separierbar parametrisch, falls existieren $l^q \in X'$ und $\Theta_l^q : \mathcal{P} \rightarrow \mathbb{R}$ für $q = 1, \dots, Q_l$ bzw. $a^q : X_1 \times X_2 \rightarrow \mathbb{R}$ stetig, bilinear und $\Theta_a^q : \mathcal{P} \rightarrow \mathbb{R}$ für $q = 1, \dots, Q_a$ mit

$$l(v; \mu) = \sum_{q=1}^{Q_l} \Theta_l^q(\mu) l^q(v) \quad \forall v \in X, \mu \in \mathcal{P}$$

$$a(u, v; \mu) = \sum_{q=1}^{Q_a} \Theta_a^q(\mu) a^q(u, v) \quad \forall u \in X_1, v \in X_2, \mu \in \mathcal{P}$$

Bemerkung.

- i) In Literatur auch “affine Annahme” oder “affin parametrisch” verwendet. Wir verwenden jedoch “separierbar”, da Θ_l^q auch nichtlinear sein können.
- ii) Q_a, Q_l sollten möglichst klein sein, weil diese in die Online-Komplexität eingehen, siehe *Abschnitt 3*.

Satz 2.5 (Energienorm)

Sei $a : X \times X \times \mathcal{P} \rightarrow \mathbb{R}$ parametrische stetige, koerzive Bilinearform, und $a_s(u, v; \mu) = \frac{1}{2}(a(u, v; \mu) + a(v, u; \mu))$ der symmetrische Anteil. Dann ist für $\mu \in \mathcal{P}$

$$\langle u, v \rangle_\mu := a_s(u, v; \mu) \quad \text{bzw.} \quad \|u\|_\mu := \sqrt{\langle u, u \rangle_\mu}$$

das *Energie-Skalarprodukt* bzw. die *Energienorm* bzgl. μ . Diese ist äquivalent zu $\|\cdot\|_X$:

$$\sqrt{\alpha(\mu)}\|u\| \leq \|u\|_\mu \leq \sqrt{\gamma(\mu)}\|u\|$$

Beweis. Skalarprodukt: klar wegen Bilinearität, Stetigkeit und Koerzivität. Normäquivalenz folgt aus Stetigkeit und Koerzivität von a_s .

$$\alpha(\mu)\|u\|^2 \leq \underbrace{a(u, u; \mu)}_{\leq \|u\|^2 \gamma(\mu)} = a_s(u, u; \mu) = \|u\|_\mu^2$$

□

Satz 2.6 (Übertragung von Koeffizienten-Eigenschaften)

Seien f bzw. a separierbar parametrische stetige Linear- bzw. Bilinearform.

- i) Falls $\Theta_f^q(\mu)$ bzw. $\Theta_a^q(\mu)$ beschränkt sind, dann sind f bzw. a gleichmäßig beschränkt bzgl. μ .
- ii) Falls $\Theta_a^q(\mu)$ strikt positiv, d.h. ex. $\bar{\Theta}$ mit $\Theta_a^q(\mu) \geq \bar{\Theta} > 0 \forall \mu \in \mathcal{P}$ alle Komponenten positiv semidefinit, d.h. $a^q(v, v) \geq 0 \forall v, q$ und $a(\cdot, \cdot; \bar{\mu})$ ist koerziv für mindestens ein $\bar{\mu} \in \mathcal{P}$, dann ist a gleichmäßig koerziv bzgl. μ .

iii) Falls Θ_f^q, Θ_a^q Lipschitz-stetig, so ist f, a Lipschitz-stetig bzgl. μ .

Beweis.

i) Sei $\bar{\Theta}_f^q \in \mathbb{R}^+$ mit $|\Theta_f^q(\mu)| \leq \bar{\Theta}_f^q \forall \mu$. Dann gilt

$$\|f(\cdot; \mu)\| = \left\| \sum_q \Theta_f^q(\mu) f^q \right\| \leq \sum_q |\Theta_f^q(\mu)| \|f^q\| \leq \sum_q \bar{\Theta}_f^q \|f^q\| =: \bar{\gamma}_f < \infty$$

analog für $a(\cdot, \cdot; \mu)$.

ii) Für $u \in X, \mu \in \mathcal{P}$ gilt

$$a(u, u; \mu) = \sum_q \Theta_a^q(\mu) a^q(u, u) = \sum_q \underbrace{\frac{\Theta_a^q(\mu)}{\Theta_a^q(\bar{\mu})}}_{>0} \underbrace{\Theta_a^q(\bar{\mu}) a^q(u, u)}_{\sum(\cdot) = a(u, u; \bar{\mu})} \geq \underbrace{\sum_q \frac{\bar{\Theta}}{\max_{q'} \Theta_a^{q'}(\bar{\mu})} \alpha(\bar{\mu})}_{=: \bar{\alpha} > 0} \|u\|^2$$

iii) Sei $|\Theta_f^q(\mu_1) - \Theta_f^q(\mu_2)| \leq L_f^q |\mu_1 - \mu_2| \forall \mu_1, \mu_2 \in \mathcal{P}$ mit geeignetem $L_f^q \in \mathbb{R}$. Dann gilt

$$\begin{aligned} |f(v; \mu_1) - f(v; \mu_2)| &= \left| \sum_q \Theta_f^q(\mu_1) f^q(v) - \sum_q \Theta_f^q(\mu_2) f^q(v) \right| \\ &\leq \sum_q |\Theta_f^q(\mu_1) - \Theta_f^q(\mu_2)| \|f^q\| \|v\| \\ &\leq \underbrace{\sum_q L_f^q \|f^q\|}_{=: L_f} \|\mu_1 - \mu_2\| \|v\| \end{aligned}$$

analog für $a(\cdot, \cdot; \mu)$.

□

Definition 2.7 (Volles Problem $(P(\mu))$)

Seien a bzw. f, l parametrische Bilinearform bzw. Linearform und gleichmäßig stetig bzgl. μ , sei a gleichmäßig koerziv bzgl. μ . Dann ist für $\mu \in \mathcal{P}$ gesucht $u(\mu) \in X$ und $s(\mu) \in \mathbb{R}$ als Lösung von

$$\begin{aligned} a(u(\mu), v; \mu) &= f(v; \mu) & \forall v \in X \\ s(\mu) &:= l(u(\mu); \mu) \end{aligned}$$

Bemerkung.

- Das volle Problem kann also ein analytisches Modell (PDE) oder ein detailliertes Modell (PDE-Diskretisierung) darstellen.
- Symmetrie von a wird nicht vorausgesetzt.

- In ??, ?? werden Verallgemeinerungen von $(P(\mu))$ betrachtet.

Satz 2.8 (Wohlgestelltheit und Stabilität)

Das Problem $(P(\mu))$ besitzt eine eindeutige Lösung mit

$$\|u(\mu)\| \leq \frac{\|f(\mu)\|_{X'}}{\alpha(\mu)} \leq \frac{\bar{\gamma}_f}{\bar{\alpha}}, \quad |s(\mu)| \leq \|l(\mu)\|_{X'} \|u(\mu)\| \leq \frac{\bar{\gamma}_l \bar{\gamma}_f}{\bar{\alpha}}$$

Beweis. Existenz, Eindeutigkeit und Schranke für $u(\mu)$ folgen mit Lax-Milgram (siehe z.B. Satz 2.5 in Braess'03). Gleichmäßige Stetigkeit und Koerzivität ergeben μ -unabhängige Schranke für $u(\mu)$. Definition von $s(\mu)$ ergibt Eindeutigkeit und entsprechende Schranken. \square

Definition 2.9 (Lösungsmannigfaltigkeit)

Wir definieren

$$\mathcal{M} := \{u(\mu) \in X : \mu \in \mathcal{P} \text{ und } u(\mu) \text{ löst } (P(\mu))\}$$

Bemerkung. Wir verwenden den Begriff “Mannigfaltigkeit” nicht im strengen differentialgeometrischen Sinn, weil keine Stetigkeit / Diffbarkeit von \mathcal{M} gefordert wird.

Beispiel 2.10 (Thermischer Block)

TODO

Beispiel 2.11 (Matrixgleichung)

- Zu $\mu \in \mathcal{P}$ suche $u(\mu) \in \mathbb{R}^H$ als Lösung von

$$A(\mu)u(\mu) = b(\mu)$$

für $A(\mu) \in \mathbb{R}^{H \times H}$ und $b(\mu) \in \mathbb{R}^H$.

- Dies ist Beispiel für $(P(\mu))$ via

$$X := \mathbb{R}^H, \quad a(u, v; \mu) := v^\top A(\mu)u, \quad f(v; \mu) := v^\top b(\mu)$$

und beliebiger linearer Ausgabe $l(v; \mu) := \underline{l}^\top v$ für $\underline{l} \in \mathbb{R}^H$.

Beispiel 2.12 ($Q_a = 1$)

Falls $a(\cdot, \cdot; \mu)$, $f(\cdot; \mu)$ separierbar parametrisch mit $Q_a = 1$ und Q_f beliebig, so ist \mathcal{M} enthalten in einem Q_f -dimensionalen linearen Teilraum von X :

$$(P(\mu)) \Rightarrow \Theta_a^1(\mu) a^1(u, v) = \sum_q \Theta_f^q(\mu) f^q(v) \quad \forall v \in X$$

$\Theta_a^1(\mu) \neq 0$ wegen a gleichmäßig koerziv

$$a^1(u, v) = \sum_q \frac{\Theta_f^q(\mu)}{\Theta_a^1(\mu)} f^q(v) \quad \forall v \in X \quad (*)$$

$a^1(\cdot, \cdot)$ ist koerziv, f^q linear und stetig

$$\begin{aligned} & \xRightarrow{\text{Lax-Milgram}} \text{ex. } u^q, q = 1, \dots, Q_f \text{ mit } a^1(u^q, v) = f^q(v), \quad v \in X \\ & \Rightarrow u := \sum_q \frac{\Theta_f^q(\mu)}{\Theta_a^1(\mu)} u^q \text{ löst } (*) \text{ wegen Linearität} \\ & \Rightarrow u \in \text{span}\{u^q\}_{q=1}^{Q_f} \end{aligned}$$

Beispiel 2.13 ($(P(\mu))$ mit vorgegebener Lösung)

Sei $u : \mathcal{P} \rightarrow X$ beliebig komplizierte Abbildung. Dann existiert ein $(P(\mu))$ mit $u(\mu)$ als Lösung via Skalarprodukten:

$$a(v, w; \mu) := \langle w, v \rangle_X, \quad f(v; \mu) := \langle u(\mu), v \rangle_X$$

d.h. Klasse der Probleme $(P(\mu))$ können beliebig komplizierte, nichtglatte oder sogar unstetige Lösungsmannigfaltigkeit \mathcal{M} besitzen.

Bemerkung (Parameter-Anzahl und Lösungskomplexität). Es gibt (sogar in der Literatur) ein Missverständnis zwischen Parameteranzahl $p \in \mathbb{N}$ und Komplexität der Lösungsmannigfaltigkeit \mathcal{M} , denn es kann Redundanz in Parametern vorliegen (siehe Thermischer Block). Extremfall: $p \in \mathbb{N}$ beliebig, für geeignetes $a(\cdot, \cdot; \mu)$, $f(\mu)$ hat $(P(\mu))$ ein \mathcal{M} , welches in einem 1D-Raum enthalten ist. (Übung) Beispiel 2.13 zeigt andererseits einen anderen Extremfall: Sogar für $p = 1$ kann bei geeignetem $(P(\mu))$ das \mathcal{M} beliebig kompliziert sein (z.B. "Raumfüllende Kurve"). Unter geeigneter Annahmen an $a(\cdot, \cdot; \mu)$ und $f(\cdot; \mu)$ können einfache Regularitätseigenschaften von $u(\mu)$ bzw. \mathcal{M} geschlossen werden.

Korollar 2.14 (Beschränktheit von \mathcal{M})

Weil $a(\cdot, \cdot; \mu)$ gleichmäßig koerziv und $f(\cdot; \mu)$ gleichmäßig beschränkt, so ist \mathcal{M} beschränkt

$$\mathcal{M} \subseteq B_{\frac{\bar{\gamma}_f}{\bar{\alpha}}}(0)$$

Beweis. Klar weil $\|u(\mu)\| \leq \frac{\bar{\gamma}_f}{\bar{\alpha}}$ nach Satz 2.8. □

Satz 2.15 (Lipschitz-Stetigkeit)

Falls $a(\cdot, \cdot; \mu)$, $f(\cdot; \mu)$, $l(\cdot; \mu)$ Lipschitz-stetig bzgl. μ , so sind $u(\mu)$ und $s(\mu)$ Lipschitz-stetig bzgl. μ mit Lipschitz-Konstanten

$$L_u = \frac{L_f}{\bar{\alpha}} + \bar{\gamma}_f \frac{L_a}{\bar{\alpha}^2} \quad \text{und} \quad L_s = L_l \frac{\bar{\gamma}_f}{\bar{\alpha}} + \bar{\gamma}_l L_u$$

Beweis. Übung. □

Satz 2.16 (Diffbarkeit)

Sei $a(u, \cdot; \mu) \in X'$ Frechet-diffbar in Umgebung von $(u_0, \mu_0) \subset X \times \mathcal{P}$ und $f(\cdot; \mu) \in X'$

Frechet-diffbar in Umgebung von $\mu_0 \in \mathcal{P}$. Dann ist Lösung $u(\mu)$ von $(P(\mu))$ Frechet-diffbar in Umgebung von $\mu_0 \in \mathcal{P}$ mit

$$D_\mu u(\mu) := - \left(\frac{\partial}{\partial u} F(u, \mu) \right)^{-1} \frac{\partial}{\partial \mu} F(u, \mu)$$

wobei $F(u, \mu) := a(u, \cdot; \mu) - f(\cdot; \mu) \in X'$.

Beweis. Aus Frechet-Diffbarkeit von $a(\cdot, \cdot; \cdot)$ und $f(\cdot; \cdot)$ folgt Frechet-Diffbarkeit von $F : X \times \mathcal{P} \rightarrow X'$ in Umgebung von (u_0, μ_0) mit partiellen Ableitungen

$$\frac{\partial}{\partial \mu} F(u_0, \mu_0) := \frac{\partial}{\partial \mu} a(u_0, \cdot; \mu_0) - \frac{\partial}{\partial \mu} f(\cdot; \mu_0) \in L(\mathbb{R}^p, X')$$

und $\frac{\partial}{\partial u} F(u_0, \mu_0) \in L(X, X')$ durch

$$\frac{\partial}{\partial u} F(u_0, \mu_0) h_u := a(h_u, \cdot; \mu_0) \in X' \quad \forall h_u \in X$$

Dann erfüllt $u(\mu)$ als Lösung von $(P(\mu))$ gerade

$$F(u(\mu), \mu) = 0$$

in Umgebung von μ_0 . Dann ist (z.B. mit Folgerung 2.15 in Ruzicka: Nichtlineare Funktionalanalysis, Springer 2004) auch $u(\mu)$ Frechet-diffbar in Umgebung von μ_0 mit Ableitung

$$D_\mu u(\mu) := - \left(\frac{\partial}{\partial u} F(u, \mu) \right)^{-1} \frac{\partial}{\partial \mu} F(u, \mu)$$

□

Bemerkung.

- Plausibilität der Ableitungsformel folgt aus formellem Ableiten:

$$\begin{aligned} & D_\mu (F(u(\mu), \mu)) = 0 \\ \Rightarrow & \frac{\partial}{\partial u} F(u(\mu), \mu) D_\mu u(\mu) + \frac{\partial}{\partial \mu} F(u, \mu) = 0 \\ \Rightarrow & \frac{\partial}{\partial u} F(u(\mu), \mu) D_\mu u(\mu) = - \frac{\partial}{\partial \mu} F(u, \mu) \\ \Rightarrow & D_\mu u(\mu) = - \left(\frac{\partial}{\partial u} F(u(\mu), \mu) \right)^{-1} \frac{\partial}{\partial \mu} F(u, \mu) \end{aligned}$$

- Man kann zeigen, dass die Sensitivitäts-Ableitungen $\partial_{\mu_i} u(\mu) \in X$ für $i = 1, \dots, p$ erfüllen das sogenannte *Sensitivitätsproblem*

$$a(\partial_{\mu_i} u(\mu), v; \mu) = \tilde{f}_i(v; u(\mu), \mu)$$

mit rechter Seite $\tilde{f}_i(\cdot; u(\mu), \mu) \in X'$ gegeben durch

$$\tilde{f}_i(\cdot; w, \mu) := \partial_{\mu_i} f(\cdot; \mu) - \partial_{\mu_i} a(w, \cdot; \mu)$$

d.h. das Problem $(P(\mu))$ mit modifizierter rechter Seite, in welcher insbesondere $u(\mu)$ eingeht. (Übung)

- Hinreichend für die Diffbarkeit von a, f in Satz 2.16 sind z.B. im Fall von separierbarer Parameterabhängigkeit die Diffbarkeit der Koeffizienten $\Theta_a^q(\mu), \Theta_f^q(\mu)$, $q = 1, \dots$ (Übung)
- Ähnliche Aussagen / Sensitivitätsprobleme gelten für Ableitungen höherer Ordnung. Also überträgt sich Glattheit der Koeffizientenfunktionen auf Glattheit der Lösung / Mannigfaltigkeit.

3 RB-Methoden für lineare koerzive Probleme

3.1 Primales RB-Problem

Definition 3.1 (Reduzierte Basis, RB-Räume)

Sei $S_N = \{\mu_1, \dots, \mu_N\} \subset \mathcal{P}$ Menge von Parametern mit (o.B.d.A.) linear unabhängigen Lösungen $\{u(\mu_i)\}_{i=1}^N$ von $(P(\mu_i))$. Dann ist $X_N := \text{span} \{u(\mu_i)\}_{i=1}^N$ ein sog. *Lagrange-RB-Raum*.

Sei $\mu^0 \in \mathcal{P}$ und $u(\mu)$ Lösung von $(P(\mu^0))$ k -mal diffbar in Umgebung von μ^0 . Dann ist

$$X_{k,\mu^0} := \text{span} \{ \partial_\sigma u(\mu^0) : \sigma \in \mathbb{N}_0^p, |\sigma| \leq k \}$$

ein *Taylor-RB-Raum*. Eine Basis $\Phi_N = \{\varphi_1, \dots, \varphi_N\} \subseteq X$ eines RB-Raums ist eine *reduzierte Basis*.

Bemerkung.

- Φ_N kann direkt aus Snapshots $u(\mu^i)$ oder, für numerische Stabilität (siehe ??), auch orthonormiert sein.
- Wahl der Parameter $\{\mu^i\}$ ist entscheidend für Güte des RB-Modells:
Hier: zufällige oder äquidistante Menge ausreichend
Später: intelligente Wahl durch a-priori Analysis oder Greedy-Verfahren
- Es ex. auch andere Arten von RB-Räumen (Hermite, POD). Gemeinsam ist diesen die Konstruktion aus Snapshots von u bzw. $\partial_\sigma u$.
- Andere MOR-Techniken: Φ_N kann auch komplett unabhängig von Snapshots auf andere Weise konstruiert werden: Balanced Truncation, Krylov-Räume, etc. (siehe z.B. Antoulas: Approximation of large scale dynamical systems, SIAM 2004)

Definition 3.2 (Reduziertes Problem $(P_N(\mu))$)

Sei eine Instanz von $(P(\mu))$ gegeben und $X_N \subseteq X$ ein RB-Raum. Zu $\mu \in \mathcal{P}$ ist die RB-Lösung $u_N(\mu) \in X_N$ und Ausgabe $s_N(\mu) \in \mathbb{R}$ gesucht mit

$$\begin{aligned} a(u_N(\mu), v; \mu) &= f(v; \mu) & \forall v \in X_N \\ s_N(\mu) &= l(u_N; \mu) \end{aligned}$$

Bemerkung.

- Wir nennen obiges “primal” weil im Fall $f \neq l$ oder a asymmetrisch, kann mit Hilfe eines geeigneten dualen Problems bessere Schätzung für s erreicht werden.
- Obiges ist “Ritz-Galerkin”-Projektion im Gegensatz zu “Petrov-Galerkin”-Projektion, welches für nicht-koerzive Probleme notwendig ist. \rightsquigarrow ??

Satz 3.3 (Galerkin-Projektion, Galerkin-Orthogonalität)

Sei $P_\mu : X \rightarrow X_N$ die orthogonale Projektion bzgl. Energieskalarprodukt $\langle \cdot, \cdot \rangle_\mu$, sei a symmetrisch und $u(\mu)$, $u_N(\mu)$ Lösung von $(P(\mu))$ bzw. $(P_N(\mu))$. Dann:

- i) $u_N(\mu) = P_\mu u(\mu)$ “Galerkin-Projektion”
 ii) $\langle e(\mu), v \rangle_\mu = 0 \quad \forall v \in X_N$, wobei $e(\mu) := u(\mu) - u_N(\mu)$

Beweis. Nach Aufgabe 1/Blatt 1 ist P_μ wohldefiniert, denn $(X, \langle \cdot, \cdot \rangle_\mu)$ ist Hilbertraum und $X_N \subseteq X$ abgeschlossen weil endlichdimensional. Orthogonale Projektion des Fehlers ergibt

$$\begin{aligned} & \langle P_\mu u(\mu) - u(\mu), \varphi_i \rangle_\mu = 0 & \forall i = 1, \dots, N \\ \Leftrightarrow & a(P_\mu u(\mu) - u(\mu), \varphi_i; \mu) = 0 & \forall i = 1, \dots, N \\ \Leftrightarrow & a(P_\mu u(\mu), \varphi_i; \mu) = a(u(\mu), \varphi_i; \mu) = f(\varphi_i; \mu) & \forall i = 1, \dots, N \end{aligned}$$

- i) also ist $P_\mu u(\mu)$ Lösung von $(P_N(\mu))$
 ii) $e(\mu)$ ist also Projektions-Fehler, orthogonal nach Aufgabe 1/Blatt 1

□

Bemerkung. Für a nichtsymmetrisch gilt immer noch folgende “Galerkin-Orthogonalität”

$$a(u - u_N, v; \mu) = 0 \quad \forall v \in X_N$$

(auch wenn a kein Skalarprodukt)

Satz 3.4 (Existenz und Eideutigkeit für $(P_N(\mu))$)

Zu $\mu \in \mathcal{P}$ ex. eindeutige Lösung $u_N(\mu) \in X_N$ und RB-Ausgabe $s_N(\mu) \in \mathbb{R}$ von $(P_N(\mu))$. Diese sind beschränkt

$$\begin{aligned} \|u_N(\mu)\| &\leq \frac{\|f(\cdot; \mu)\|_{X'}}{\alpha(\mu)} \leq \frac{\bar{\gamma}_f}{\bar{\alpha}} \\ \|s_N(\mu)\| &\leq \|l(\cdot; \mu)\| \|u_N(\mu)\| \leq \frac{\bar{\gamma}_l \bar{\gamma}_f}{\bar{\alpha}} \end{aligned}$$

Beweis. Weil $X_N \subset X$ ist $a(\cdot, \cdot; \mu)$ stetig und koerziv auf X_N .

$$\begin{aligned} \alpha_N(\mu) &:= \inf_{v \in X_N} \frac{a(v, v; \mu)}{\|v\|^2} \geq \inf_{v \in X} \frac{a(v, v; \mu)}{\|v\|^2} = \alpha(\mu) > 0 \\ \gamma_N(\mu) &:= \sup_{u, v \in X_N} \frac{a(u, v; \mu)}{\|u\| \|v\|} \leq \sup_{u, v \in X} \frac{a(u, v; \mu)}{\|u\| \|v\|} = \gamma(\mu) < \infty \end{aligned}$$

analog f, l stetig auf X_N . Existenz, Eindeutigkeit und Schranken folgen also mit Lax-Milgram analog zu 2.8. □

Korollar 3.5 (Lipschitz-Stetigkeit)

Seien f, l gleichmäßig beschränkt und a, f, l Lipschitz-stetig bzgl. μ , dann sind auch $u_N(\mu), s_N(\mu)$ Lipschitz-stetig bzgl. μ mit L_u, L_s wie in 2.15.

Beweis. Analog zu 2.15 / Übung. □

Satz 3.6 (Diskrete RB-Probleme)

Sei $\Phi_N = \{\varphi_1, \dots, \varphi_N\}$ eine reduzierte Basis für X_N . Für $\mu \in \mathcal{P}$,

$$\begin{aligned} A_N(\mu) &:= (a(\varphi_j, \varphi_i; \mu))_{i,j=1}^N && \in \mathbb{R}^{N \times N} \\ \underline{l}_N(\mu) &:= (l(\varphi_i; \mu))_{i=1}^N && \in \mathbb{R}^N \\ \underline{f}_N(\mu) &:= (f(\varphi_i; \mu))_{i=1}^N && \in \mathbb{R}^N \end{aligned}$$

und $\underline{u}_N = (u_{N,i})_{i=1}^N \in \mathbb{R}^N$ als Lösung von

$$A_N(\mu) \underline{u}_N = \underline{f}_N(\mu) \quad (3.1)$$

Dann ist $u_N(\mu) := \sum_{i=1}^N u_{N,i} \varphi_i$ und $s_N(\mu) := \underline{l}_N^\top(\mu) \underline{u}_N$.

Beweis. Einsetzen und Linearität zeigt, dass

$$a\left(\sum u_{N,j} \varphi_j, \varphi_i; \mu\right) = (A_N(\mu) \underline{u}_N)_i = (\underline{f}_N)_i = f(\varphi_i; \mu)$$

□

Satz 3.7 (Kondition bei ONB und Symmetrie)

Falls $a(\cdot, \cdot; \mu)$ symmetrisch und Φ_N ist ONB, so ist Kondition von (3.1) unabhängig von N beschränkt

$$\text{cond}_2(A_N) := \|A_N\|_2 \|A_N^{-1}\|_2 \leq \frac{\gamma(\mu)}{\alpha(\mu)}$$

Beweis. Wegen Symmetrie gilt

$$\text{cond}_2(A_N) = \frac{|\lambda_{\max}|}{|\lambda_{\min}|} \quad (3.2)$$

mit betragsmäßig größtem/kleinstem Eigenwert $\lambda_{\max}/\lambda_{\min}$ von $A_N(\mu)$. Sei $\underline{u}_{\max} = (u_i)_{i=1}^N \in \mathbb{R}^N$ Eigenvektor zu λ_{\max} und

$$\underline{u}_{\max} := \sum_{i=1}^N u_i \varphi_i \in X_N$$

Dann gilt

$$\begin{aligned} \lambda_{\max} \|\underline{u}_{\max}\|^2 &= \lambda_{\max} \underline{u}_{\max}^\top \underline{u}_{\max} = \underline{u}_{\max}^\top A_N \underline{u}_{\max} \\ &= \sum_{i,j=1}^N u_i u_j a(\varphi_j, \varphi_i; \mu) = a\left(\sum_j u_j \varphi_j, \sum_i u_i \varphi_i; \mu\right) \\ &= a(\underline{u}_{\max}, \underline{u}_{\max}; \mu) \leq \gamma(\mu) \|\underline{u}_{\max}\|^2 \end{aligned}$$

Wegen

$$\|\underline{u}_{\max}\|^2 = \left\langle \sum u_i \varphi_i, \sum u_j \varphi_j \right\rangle = \sum u_i u_j \langle \varphi_i, \varphi_j \rangle = \sum u_i^2 = \|\underline{u}_{\max}\|^2$$

folgt $|\lambda_{\max}| \leq \gamma(\mu)$. Analog zeigt man $|\lambda_{\min}| \geq \alpha(\mu)$ also folgt mit (3.2) die Behauptung. □

Bemerkung (Unterschied FEM zu RB). Es bezeichne $A_h(\mu) \in \mathbb{R}^{H \times H}$ die FEM Matrix (oder FV/FD).

- i) Die RB-Matrix $A_N(\mu) \in \mathbb{R}^{H \times H}$ ist klein aber typischerweise vollbesetzt im Gegensatz zur großen aber dünnbesetzten Matrix A_h .
- ii) Die Kondition von A_N verschlechtert sich nicht mit wachsendem N (falls eine ONB verwendet wird), während die Konditionszahl von A_h typischerweise polynomiell in H wächst, also schlechter wird.

Satz 3.8 (Reproduktion von Lösungen)

Seien $u(\mu)$, $u_N(\mu)$ Lösungen von $(P(\mu))$ bzw. $(P_N(\mu))$, $e_i \in \mathbb{R}^n$ i -ter Einheitsvektor

- i) Falls $u(\mu) \in X_N \Rightarrow u_N(\mu) = u(\mu)$
- ii) Falls $u(\mu) = \varphi_i \in \Phi_N \Rightarrow u_N(\mu) = e_i \in \mathbb{R}^N$

Beweis.

- i) Mit $u(\mu), u_N(\mu) \in X_N \Rightarrow e := u(\mu) - u_N(\mu) \in X_N$. Wegen Galerkin-Orthogonalität ($a(e, v; \mu) = 0 \forall v \in X_N$) und Koerzivität folgt:

$$0 = a(e, e; \mu) \geq \underbrace{\alpha(\mu)}_{>0} \underbrace{\|e\|^2}_{\geq 0} \Rightarrow \|e\| = 0 \Rightarrow e = 0 \Rightarrow u = u_N$$

- ii) $u_N(\mu) = \varphi_i$, nach i). Mit Eindeutigkeit der Basisexpansion folgt die Behauptung. □

Bemerkung.

- Reproduktion von Lösungen ist grundlegende Konsistenzeigenschaft. Es gilt trivialerweise falls/sobald Fehlerschranken vorliegen, aber für komplexe RB-Probleme ohne Fehlerschranken ist obiges ein guter Test.
- Validierung für Programmcode: Wähle Basis aus Snapshots $\varphi_i = u(\mu^i)$, $i = 1, \dots, N$, ohne Orthonormierung, dann muss $u_N(\mu^i) = e_i \in \mathbb{R}^N$ ein Einheitsvektor sein.

3.2 Fehleranalyse

Satz 3.9 (Céa, Beziehung zur Bestapproximation)

Für alle $\mu \in \mathcal{P}$ gilt

$$\|u(\mu) - u_N(\mu)\| \leq \frac{\gamma(\mu)}{\alpha(\mu)} \inf_{v \in X} \|u - v\|$$

Beweis. $\forall v \in X_N$ mit Stetigkeit und Koerzivitat

$$\begin{aligned}\alpha \|u - u_N\|^2 &\leq a(u - u_N, u - u_N) = a(u - u_N, u - v) + \underbrace{a(u - u_N, v - u_N)}_{=0 \text{ (Galerkin-Orth.)}} \\ &\leq \gamma(\mu) \|u - u_N\| \|u - v\|\end{aligned}$$

Division durch α , $\|u - u_N\|$ liefert

$$\|u - u_N\| \leq \frac{\gamma}{\alpha} \|u - v\|$$

also Behauptung durch Infimum-Bildung. \square

Bemerkung.

- i) hnliche Bestapproximationsaussagen gelten auch fur andere Interpolationstechniken, aber die zugehorige Lebesgue-Konstante divergiert meist mit wachsender Dimension N . Obiges ist konzeptioneller Vorteil von Galerkin-Projektion uber anderen Interpolationstechniken, da $\frac{\gamma}{\alpha}$ unabhangig von N beschrankt bleibt. “Quasi-Optimalitat” der Galerkin-Projektion/des RB-Ansatzes.
- ii) Falls $a(\cdot, \cdot; \mu)$ zusatzlich symmetrisch ist, kann um eine “Wurzel” verbessert werden mittels Normaquivalenz 2.5 und Bestapproximation der orthogonalen Projektion (Aufg. 1/Blatt 1)

$$\begin{aligned}\sqrt{\alpha} \|u - u_N\| &\stackrel{2.5}{\leq} \|u - u_N\|_\mu = \|u - P_\mu u\|_\mu = \inf_{v \in X_N} \|u - v\|_\mu \stackrel{2.5}{\leq} \sqrt{\gamma} \inf_{v \in X_N} \|u - v\| \\ \Rightarrow \|u - u_N\| &\leq \sqrt{\frac{\gamma}{\alpha}} \inf_{v \in X_N} \|u - v\|\end{aligned}$$

- iii) Implikation von 3.9: Wahle guten Approximationsraum X_N , so wird Galerkin-Projektion/RB-Approximation auch garantiert gut sein.

Satz 3.10 (Ausgabe und Bestapproximation)

- i) Fur alle $\mu \in \mathcal{P}$ gilt

$$|s(\mu) - s_N(\mu)| \leq \|l(\cdot; \mu)\|_{X'} \frac{\gamma(\mu)}{\alpha(\mu)} \inf_{v \in X_N} \|u - v\|$$

- ii) Fur den sog. “compliant” Fall (d.h. $a(\cdot, \cdot; \mu)$ symmetrisch und $l = f$) gilt sogar

$$\begin{aligned}0 \leq s(\mu) - s_N(\mu) &= \|u - u_N\|_\mu^2 \\ &= \inf_{v \in X_N} \|u - v\|_\mu^2 \\ &\leq \gamma(\mu) \inf_{v \in X_N} \|u - v\|^2\end{aligned}$$

Beweis.

i) Klar mit Céa, Bestapproximation und Linearität

$$|s(\mu) - s_N(\mu)| = |l(u) - l(u_N)| = |l(u - u_N)| \leq \|l\| \|u - u_N\| \leq \|l\| \frac{\gamma}{\alpha} \inf_{v \in X_N} \|u - v\|$$

ii) Wegen $a(\cdot, \cdot; \mu)$ symmetrisch gilt wie in voriger Bemerkung

$$\|u - u_N\|_\mu = \|u - P_\mu u\|_\mu = \inf_{v \in X_N} \|u - v\| \quad (3.3)$$

Damit

$$\begin{aligned} s(\mu) - s_N(\mu) &= l(u) - l(u_N) \stackrel{f=l}{=} f(u) - f(u_N) = f(u - u_N) \\ &= a(u, u - u_N) - \underbrace{a(u_N, u - u_N)}_{=0 \text{ (Gal.-Orth./Symm.)}} = \|u - u_N\|_\mu^2 \\ &\stackrel{3.3}{=} \inf_{v \in X_N} \|u - v\|_\mu^2 \\ &\stackrel{2.5}{\leq} \gamma \inf_{v \in X_N} \|u - v\|^2 \end{aligned}$$

Also insbesondere $s - s_N = \|u - u_N\|_\mu^2 \geq 0$.

□

Bemerkung.

- Im “compliant” Fall ist der Ausgabefehler i.A. sehr klein, da das Quadrat des RB-Fehlers eingeht.
- Im “nicht-compliant” Fall geht der RB-Fehler nur linear in die Schranke ein, das wird später durch primal-duale Technik verbessert.
- Aus ii) folgt nicht nur Fehlerschranke, sondern sogar Vorzeichen-Information, $s_N(\mu)$ ist untere Schranke für s .

Korollar 3.11 (Monotoner Fehlerabfall in Energienorm)

Falls $a(\cdot, \cdot; \mu)$ symmetrisch, $(X_N)_{N=1}^{N_{\max}}$ Folge von RB-Räumen, mit $X_N \subseteq X_{N'}, \forall N \leq N'$ (“hierarchische Räume”) und für $\mu \in \mathcal{P}$ setze $e_{u,N} := u(\mu) - u_N(\mu)$, $e_{s,N} := s(\mu) - s_N(\mu)$.

i) Dann ist $(\|e_{u,N}\|_\mu)_{N=1}^{N_{\max}}$ monoton fallend.

ii) Falls $l = f$ (also “compliant” Fall) ist $e_{s,N}$ monoton fallend.

Beweis.

i) Mit (3.3) gilt für $N \leq N'$

$$\|e_{u,N}\|_\mu = \|u - u_N\|_\mu \stackrel{(3.3)}{=} \inf_{v \in X_N} \|u - v\|_\mu \geq \inf_{v \in X_{N'}} \|u - v\|_\mu \stackrel{(3.3)}{=} \|e_{u,N'}\|_\mu$$

ii) Mit Satz 3.10 ii) gilt

$$e_{s,N} = \|e_{u,N}\|_\mu^2, \text{ also Behauptung folgt mit i)}$$

□

Bemerkung.

- “Worst-case” ist Stagnation des Fehlers (unrealistisch, jeder neue Basisvektor müsste orthogonal zum Fehler $e_N(\mu)$ sein). In Praxis ist bei geschickter Basiswahl und “glatten” Problemen exponentielle Konvergenz zu erwarten, siehe Basisgenerierung, §3.5.
- Monotonie gilt nicht notwendigerweise bezüglich anderen Normen trotz Normäquivalenz

$$c\|e_{u,N}\|_\mu \leq \|e_{u,N}\| \leq C\|e_{u,N}\|_\mu, \text{ mit } c, C \text{ unabhängig von } N$$

Fehlernorm $\|e_{u,N}\|$ kann gelegentlich anwachsen, bleibt aber in einem “Korridor”, welcher monoton fällt.




Abbildung 5: Fehlerabfall mit wachsender reduzierter Dimension.
(aus B. Haasdonk, Reduzierte-Basis-Methoden, Skript zur Vorlesung SS 2011, Universität Stuttgart, IANS-Report 4/11, 2011.)

Bemerkung (Gleichmäßige Konvergenz von Lagrange RB-Ansatz).

- Sei \mathcal{P} kompakt und $S_N := \{\mu^1, \dots, \mu^N\} \subset \mathcal{P}$, $N \in \mathbb{N}$, sodass die sog. Füll-Distanz (fill-distance) h_N gegen 0 geht:

$$h_N := \sup_{\mu \in \mathcal{P}} \text{dist}(\mu, S_N), \quad \text{dist}(\mu, S_N) := \min_{\mu' \in S_N} \|\mu - \mu'\|$$

$$\lim_{N \rightarrow \infty} h_N = 0$$

- Falls $u(\mu)$, $u_N(\mu)$ Lipschitz-stetig mit Lipschitz-Konstante L_u unabhängig von N , so folgt für alle N , μ und “nächstes” $\mu^* := \arg \min_{\mu' \in S_N} \|\mu - \mu'\|$:

$$\begin{aligned} \|u(\mu) - u_N(\mu)\| &\leq \|u(\mu) - u(\mu^*)\| + \|u(\mu^*) - u_N(\mu^*)\| + \|u_N(\mu^*) - u_N(\mu)\| \\ &\leq L_u \underbrace{\|\mu - \mu^*\|}_{\leq h_N} + 0 + L_u \underbrace{\|\mu - \mu^*\|}_{\leq h_N} \leq 2L_u h_N \end{aligned}$$

- Also folgt uniforme Konvergenz

$$\lim_{N \rightarrow \infty} \sup_{\mu \in \mathcal{P}} \|u(\mu) - u_N(\mu)\| = 0$$

- Jedoch Konvergenzrate linear in h_N ist nicht praktisch bedeutsam, weil h_N sehr langsam mit N abfällt, also muss N sehr groß sein, um kleinen Fehler zu garantieren.
- Wir werden sehen, dass bei gleichmäßig koerziven Problemen und geschickter Wahl der μ^i sogar exponentielle Konvergenz erreicht wird.

Lemma 3.12 (Fehler-Residuums-Beziehung)

Für $\mu \in \mathcal{P}$ definieren wir mittels der RB-Lösung u_N das Residuum $r(\cdot; \mu) \in X'$ bzw. seinen Riesz-Repräsentanten $v_r(\mu) \in X$

$$\langle v_r(\mu), v \rangle_X := r(v; \mu) := f(v; \mu) - a(u_N(\mu), v; \mu) \quad \forall v \in X$$

Dann erfüllt der Fehler $e(\mu) := u(\mu) - u_N(\mu)$

$$a(e(\mu), v; \mu) = r(v; \mu) \quad \forall v \in X$$

Beweis. $a(e(\mu), v; \mu) = \underbrace{a(u, v)}_{f(v)} - a(u_N, v) = r(v)$ □

Bemerkung.

- Fehler erfüllt “ $(P(\mu))$ mit Residuum als rechte Seite”
- Insbesondere ist $r(v; \mu) = 0 \quad \forall v \in X_N$ (wegen Galerkin-Orthogonalität)
- $r(\cdot; \mu) = 0 \quad \Rightarrow \quad e = 0$

Satz 3.13 (A-posteriori Fehlerschätzer, absoluter Fehler)

Sei $\mu \in \mathcal{P}$, $u(\mu)$ bzw. $u_N(\mu)$ Lösung von $(P(\mu))$, $(P_N(\mu))$ und $e = u - u_N$. Sei $\alpha_{LB}(\mu)$ eine untere Schranke für $\alpha(\mu)$ und $v_r \in X$ Riesz-Repräsentant von $r(\cdot; \mu)$ aus Lemma 3.12. Dann gelten folgende Schranken

i) Fehler in Energienorm

$$\|e(\mu)\|_\mu \leq \Delta_N^{en}(\mu) := \frac{\|v_r\|}{\sqrt{\alpha_{LB}(\mu)}}$$

ii) Fehler in X -Norm $\|\cdot\|$

$$\|e(\mu)\| \leq \Delta_N(\mu) := \frac{\|v_r\|}{\alpha_{LB}(\mu)}$$

iii) Ausgabefehler

$$|s(\mu) - s_N(\mu)| \leq \Delta_{N,s}(\mu) := \|l(\cdot; \mu)\| \Delta_N(\mu)$$

Beweis.

i) Normäquivalenz 2.5 impliziert

$$\|e\| \leq \frac{\|e\|_\mu}{\sqrt{\alpha_{LB}(\mu)}}$$

Damit folgt

$$\|e\|_\mu^2 = a_s(e, e) = a(e, e) = r(v) = \langle v_r, e \rangle \leq \|v_r\| \|e\| \leq \frac{\|v_r\|}{\sqrt{\alpha_{LB}(\mu)}}$$

Division durch $\|e\|_\mu$ liefert die Behauptung i).

ii) Koerzivität liefert

$$\alpha_{LB}(\mu) \|e\|^2 \leq a(e, e) = r(e) = \langle v_r, e \rangle \leq \|v_r\| \|e\|$$

Division durch α_{LB} und $\|e\|$ liefert ii).

iii) Stetigkeit von l liefert

$$|s(\mu) - s_N(\mu)| = |l(u - u_N; \mu)| \leq \|l\| \|u - u_N\| \stackrel{ii)}{\leq} \|l\| \Delta_N$$

□

Bemerkung.

- $\alpha_{LB}(\mu)$ soll eine *schnell berechenbare* untere Schranke an $\alpha(\mu)$ sein, z.B. $\alpha_{LB}(\mu) := \bar{\alpha}$ falls $\bar{\alpha}$ bekannt, andere Möglichkeiten folgen später (“min Θ ”, “SCM”).
- Δ_N ist also immer um Faktor $\sqrt{\alpha_{LB}(\mu)}$ schlechter.
- Beschränkung des Fehlers durch Residuums-Norm ist bekannte Technik aus FEM, um FEM-Lösung u_h gegen Sobolev-Raum Lösung u abzuschätzen. In diesem Fall ist X ∞ -dimensional und Residuums-Norm algorithmisch nicht berechenbar. In RB-Methoden wird $\|v_r\|$ eine *berechenbare* Größe sobald X endlich-dimensional, z.B. FEM-Raum, ist. Für Residuum ist $u_N(\mu)$ erforderlich, daher sind Schranken “*a posteriori*”.
- Allgemeines Vorgehen (und alternative Begründung für ii)) zur Herleitung von Fehlerschranken: Zeige, dass Fehler e erfüllt $(P(\mu))$ mit rechter Seite, genannt r (Residuum), wende a-priori Stabilitätsaussage an:

$$\|e\| \leq \frac{\|r\|}{\alpha(\mu)} \quad \text{z.B. Lax-Milgram}$$

und erhalte berechenbare Größe durch Wahl $X = X_{FEM}$ und untere Schranke $\alpha_{LB}(\mu) \leq \alpha(\mu)$.

- Weil die Schranken beweisbare obere Schranken an Fehler darstellen, nennt man sie “rigorose” Fehlerschranken (vgl. “zuverlässige” Schätzer in FEM, bei denen jedoch die Konstante unbekannt ist).
- Fehlerschranken liefern eine Absicherung für RB-Methoden, “certified” RB-Methode, im Gegensatz zu vielen anderen Reduktionsmethoden (z.B. Krylov-Raum-Methoden).
- Ausgabefehler ist grob, indem Δ_N nur linear eingeht. Verbesserungen können für den “compliant” Fall oder mit primal-dual Techniken erreicht werden. (\rightsquigarrow §??)

Korollar 3.14 (Verschwindende Fehlerschranke)

Falls $u(\mu) = u_N(\mu)$ dann ist $\Delta_N(\mu) = \Delta_N^{en}(\mu) = \Delta_{N,s}(\mu) = 0$

Beweis.

$$\begin{aligned} 0 &= a(0, v; \mu) = a(e, v; \mu) = r(v; \mu) \\ \Rightarrow r &\equiv 0 \Rightarrow \|v_r\| = 0 \Rightarrow \Delta_N = \Delta_N^{en} = \Delta_{N,s} = 0 \end{aligned}$$

□

Bemerkung.

- Dies ist initialer Wunsch an eine Fehlerschranke: diese soll verschwinden falls exakte Approximation vorliegt. Dies ist Grundlage dafür, dass der Faktor der Überschätzung endlich ist.
- Aussage ist trivial für *effektive* Fehlerschätzer (sehen wir bald), aber in komplexen Problemen kann 3.14 schon das maximal erreichbare sein.
- 3.14 ist wieder sinnvoll um Programmcode zu validieren.

Satz 3.15 (A-posteriori Fehlerschranken, relative Fehler)

Mit Bezeichnungen/Voraussetzungen aus 3.13 und unter Annahme, dass alle Brüche im Folgenden wohldefiniert sind, gilt:

i) Für den relativen Fehler gilt in Energienorm:

$$\frac{\|e(\mu)\|_\mu}{\|u(\mu)\|_\mu} \leq \Delta_N^{en,rel}(\mu) := 2 \frac{\|v_r\|}{\sqrt{\alpha_{LB}(\mu)}} \cdot \frac{1}{\|u_N(\mu)\|_\mu} \quad \text{falls} \quad \Delta_N^{en,rel} \leq 1$$

ii) Für den relativen Fehler gilt in X -Norm:

$$\frac{\|e(\mu)\|}{\|u(\mu)\|} \leq \Delta_N^{rel}(\mu) := 2 \frac{\|v_r\|}{\alpha_{LB}(\mu)} \cdot \frac{1}{\|u_N(\mu)\|} \quad \text{falls} \quad \Delta_N^{rel} \leq 1$$

Beweis.

i) Falls $\Delta_N^{en,rel}(\mu) \leq 1$, so ist

$$\begin{aligned} \left| \frac{\|u\|_\mu - \|u_N\|_\mu}{\|u_N\|_\mu} \right| &\stackrel{\Delta\text{-Ungl.}}{\leq} \frac{\|u - u_N\|_\mu}{\|u_N\|_\mu} = \frac{\|e\|_\mu}{\|u_N\|_\mu} \stackrel{3.13 \text{ i)}}{\leq} \frac{\|v_r\|}{\sqrt{\alpha_{LB}(\mu)} \|u_N\|_\mu} \\ &= \frac{1}{2} \Delta_N^{en,rel}(\mu) \leq \frac{1}{2} \end{aligned}$$

Falls $\|u_N\|_\mu > \|u\|_\mu$ gilt $\|u_N\|_\mu - \|u\|_\mu \leq \frac{1}{2} \|u_N\|_\mu$ also

$$\frac{1}{2} \|u_N\|_\mu \leq \|u\|_\mu \quad (*)$$

Falls $\|u\|_\mu \geq \|u_N\|_\mu$, so ist $(*)$ klar. Damit folgt

$$\frac{\|e\|_\mu}{\|u\|_\mu} \stackrel{3.13 \text{ i)}}{\leq} \frac{\|v_r\|}{\sqrt{\alpha_{LB}}} \cdot \frac{1}{\|u\|_\mu} \stackrel{(*)}{\leq} \frac{\|v_r\|}{\sqrt{\alpha_{LB}}} \cdot \frac{1}{\|u_N\|_\mu} \cdot 2 = \Delta_N^{en,rel}(\mu)$$

ii) analog zu i).

□

Bemerkung.

- Analog folgt auch relativer Ausgabefehlerschätzer

$$\frac{|s(\mu) - s_N(\mu)|}{|s(\mu)|} \leq \Delta_{N,s}^{rel}(\mu) := \frac{\|l(\cdot; \mu)\| \cdot \Delta_N}{|s_N(\mu)|} \cdot 2 \quad \text{falls} \quad \Delta_{N,s}^{rel}(\mu) \leq 1$$

- Relative Fehlerschranken sind nur mit Zusatzbedingung $(\Delta_*^{rel} \leq 1)$ gültig. Diese Bedingung ist jedoch konkret überprüfbar. Falls $\Delta_N^{rel}(\mu) > 1$, sollte der RB-Raum verbessert werden.

Satz 3.16 (Effektivität der Fehlerschranken)

Mit Bezeichnungen aus 3.13 sei $u(\mu) \neq u_N(\mu)$ und $\gamma_{UB}(\mu) < \infty$ eine obere Schranke an $\gamma(\mu)$. Dann sind die *Effektivitäten* $\eta_N^{en}(\mu)$ und $\eta_N(\mu)$ definiert und beschränkt durch

i)

$$\eta_N^{en}(\mu) := \frac{\Delta_N^{en}(\mu)}{\|e\|_\mu} \leq \frac{\gamma_{UB}(\mu)}{\alpha_{LB}(\mu)}$$

Falls $a(\cdot, \cdot; \mu)$ symmetrisch, gilt sogar $\eta_N^{en}(\mu) \leq \sqrt{\frac{\gamma_{UB}(\mu)}{\alpha_{LB}(\mu)}}$

ii)

$$\eta_N(\mu) := \frac{\Delta_N(\mu)}{\|e\|_\mu} \leq \frac{\gamma_{UB}(\mu)}{\alpha_{LB}(\mu)}$$

Beweis.

$$\begin{aligned} \text{ii) } \|v_r\|^2 &= \langle v_r, v_r \rangle = r(v_r) = a(e, v_r) \leq \gamma_{UB}(\mu) \|e\| \|v_r\| \\ \|v_r\| &\leq \gamma_{UB}(\mu) \|e\| \end{aligned} \quad (3.4)$$

Damit

$$\frac{\Delta_N(\mu)}{\|e\|} = \frac{\|v_r\|}{\alpha_{LB}} \cdot \frac{1}{\|e\|} \stackrel{(3.4)}{\leq} \frac{\gamma_{UB}}{\alpha_{LB}} \cdot \frac{\|e\|}{\|e\|}$$

i)

$$\frac{\Delta_N^{en}(\mu)}{\|e\|_\mu} = \frac{\|v_r\|}{\sqrt{\alpha_{LB}}} \cdot \frac{1}{\underbrace{\|e\|_\mu}_{\geq \sqrt{\alpha_{LB}} \cdot \|e\|}} \leq \frac{\|v_r\|}{\alpha_{LB}} \cdot \frac{1}{\|e\|} \stackrel{\text{ii)}}{\leq} \frac{\gamma_{UB}}{\alpha_{LB}}$$

Falls $a(\cdot, \cdot)$ symmetrisch, gilt wegen Normäquivalenz

$$\|v_r\|_\mu \leq \sqrt{\gamma_{UB}} \|v_r\|$$

und

$$\|v_r\|^2 = a(e, v_r) \stackrel{\text{CS}}{\leq} \|e\|_\mu \|v_r\|_\mu \Rightarrow \|v_r\| \leq \|e\|_\mu \cdot \sqrt{\gamma_{UB}}$$

Damit

$$\frac{\Delta_N^{en}(\mu)}{\|e\|_\mu} = \frac{\|v_r\|}{\sqrt{\alpha_{LB}}} \cdot \frac{1}{\|e\|_\mu} \leq \frac{\|e\|_\mu \cdot \sqrt{\gamma_{UB}}}{\sqrt{\alpha_{LB}} \cdot \|e\|_\mu}$$

□

Bemerkung.

- Wir nennen Δ_N, Δ_N^{en} daher “effektive” Fehlerschranken weil Faktor der Überschätzung höchstens $\frac{\gamma_{UB}}{\alpha_{LB}}$ beträgt.
- “Rigorousität” also äquivalent mit $\eta_N(\mu) \geq 1$.
- Für den Ausgabefehler $\Delta_{N,s}(\mu)$ ohne weitere Annahmen keine Effektivität beweisbar. Tatsächlich kann $\frac{\Delta_{N,s}}{|s-s_N|}$ beliebig groß oder nicht definiert sein, falls $\Delta_{N,s} \neq 0$, aber $s(\mu) = s_N(\mu)$:

Wähle X_N und μ so dass $u(\mu) \neq u_N(\mu)$, wird erreicht durch $u(\mu) \notin X_N$

$$\Rightarrow e(\mu) \neq 0 \Rightarrow \Delta_N \neq 0, \Delta_{N,s} \neq 0 \quad \text{falls } l \neq 0$$

Wähle $l(\cdot; \mu) \neq 0$, so dass $l(u - u_N; \mu) = 0$

$$\Rightarrow s(\mu) - s_N(\mu) = l(u - u_N; \mu) = 0$$

- Wir nennen die Fehlerschranken auch *Fehlerschätzer* weil sie äquivalent zum Fehler sind.

$$\|e\| \leq \Delta_N \leq \eta_N \|e\|$$

Satz 3.17 (Effektivität, relative Fehlerschätzer)

Für $\Delta_N^{rel}(\mu)$ aus 3.15 ist Effektivität definiert und beschränkt durch

$$\eta_N^{rel}(\mu) := \frac{\Delta_N^{rel}(\mu)}{\frac{\|e\|}{\|u\|}} \leq 3 \frac{\gamma_{UB}(\mu)}{\alpha_{LB}(\mu)} \quad \text{falls} \quad \Delta_N^{rel}(\mu) \leq 1$$

Beweis. Wie in Beweis zu 3.15 impliziert $\Delta_N^{rel} \leq 1$:

$$\left| \frac{\|u\| - \|u_N\|}{\|u\|} \right| \leq \frac{1}{2}$$

Falls $\|u_N\| \leq \|u\|$ so gilt $\|u\| - \|u_N\| \leq \frac{1}{2}\|u_N\|$ also

$$\|u\| \leq \frac{3}{2}\|u_N\|$$

Falls $\|u_N\| > \|u\|$, so ist (*) klar. Dann gilt

$$\eta_N^{rel}(\mu) = \underbrace{\frac{2\|v_r\|}{\alpha_{LB}(\mu)\|u_N\|}}_{\Delta_N^{rel}} \cdot \frac{1}{\frac{\|e\|}{\|u\|}} \stackrel{(3.4)}{\leq} 2 \frac{\gamma_{UB}\|e\|}{\alpha_{LB}\|e\|} \cdot \frac{\|u\|}{\|u_N\|} \stackrel{(*)}{\leq} 3 \frac{\gamma_{UB}}{\alpha_{LB}}$$

□

Bemerkung.

- Ähnlich für $\Delta_N^{en,rel}$
- Verbesserung von Schranken und Effektivität durch Normwechsel.

Wähle $\bar{\mu} \in \mathcal{P}$ und $\|u\| := \|u\|_{\bar{\mu}}$ als neue Norm auf X . Dann gilt für symmetrisches a : $\alpha(\bar{\mu}) = 1 = \gamma(\bar{\mu})$ also Effektivitäten $\eta_N, \eta_N^{en} = 1$, Schätzer sind genau der echte Fehler. Dies lässt u_N unberührt, liefert aber bessere Fehlerschätzung. Im Fall von Stetigkeit bzgl. μ kann auch in Umgebung von $\bar{\mu}$ gute Effektivität erwartet werden.

Satz 3.18 (Ausgabefehlerschranke und Effektivität, compliant Fall)

Sei $a(\cdot, \cdot; \mu)$ symmetrisch, $l = f$. Dann erhalte verbesserte Ausgabeschranke

$$0 \leq s(\mu) - s_N(\mu) \leq \bar{\Delta}_{N,s}(\mu) := \frac{\|v_r\|^2}{\alpha_{LB}}$$

und Effektivität

$$\bar{\eta}_{N,s}(\mu) := \frac{\bar{\Delta}_{N,s}(\mu)}{s(\mu) - s_N(\mu)} \leq \frac{\gamma_{UB}(\mu)}{\alpha_{LB}(\mu)}$$

Beweis. Nach Satz 3.10 ii) und 3.13 gilt

$$0 \stackrel{3.10}{\leq} s(\mu) - s_N(\mu) = \|u - u_N\|_{\mu}^2 = \|e\|_{\mu}^2 \stackrel{3.13}{\leq} \Delta_N^{en}(\mu)^2 = \bar{\Delta}_{N,s}(\mu)$$

Für Effektivität gilt entsprechend mit 3.16 i)

$$\bar{\eta}_{N,s}(\mu) = \frac{\bar{\Delta}_{N,s}}{s(\mu) - s_N(\mu)} \stackrel{3.10}{=} \frac{\Delta_N^{en}(\mu)^2}{\|u - u_N\|_\mu^2} = \eta_N^{en}(\mu)^2 \stackrel{3.16}{=} \sqrt{\frac{\gamma_{UB}}{\alpha_{LB}}}^2 = \frac{\gamma_{UB}}{\alpha_{LB}}$$

□

Bemerkung. Analog kann man im compliant Fall eine relative Ausgabefehlerschranke und Effektivität beweisen.

$$\frac{s(\mu) - s_N(\mu)}{s(\mu)} \leq \bar{\Delta}_{N,s}^{rel}(\mu) := \frac{\|v_r\|^2}{\alpha_{LB} s_N(\mu)}$$

und

$$\bar{\eta}_{N,s}^{rel}(\mu) := \frac{\bar{\Delta}_{N,s}^{rel}}{\frac{s(\mu) - s_N(\mu)}{s(\mu)}} \leq 2 \frac{\gamma_{UB}(\mu)}{\alpha_{LB}(\mu)}$$

falls $\bar{\Delta}_{N,s}^{rel}(\mu) \leq 1$.

Bemerkung (Zusammenfassende Relevanz der Fehlerschätzer).

- Rigorose obere Schranke für tatsächlichen Fehler nicht nur “Indikatoren” wie bei FEM.
- Effektivität Faktor der Überschätzung des Fehlers ist klein und bleibt beschränkt. Insbesondere:

$$e(\mu) = 0 \Rightarrow \Delta_N(\mu) = 0$$

also “a-posteriori” exakte Approximation verifizierbar.

- Theoretische Untermauerung der i.A. empirischen Basiswahl.
- Unabhängig von Basiswahl sind Fehlerschätzer anwendbar, auch für nicht-Snapshot-Basen (z.B. Krylov-Unterräume, etc.).
- Effiziente Berechnung: Durch Offline-Online-Zerlegung (\leadsto §3.3) ist neben reduzierter Simulation auch Fehlerschranken & Effektivitätsschranken schnell berechenbar.
- Weitere Einsatzmöglichkeiten: Offline zur Basisgenerierung (\leadsto §3.5) und Online zur adaptiven Dimensionswahl.

Numerische Beispiele

demos_chapter3(1) Thermischer Block aus Beispiel 2.10, $B_1 = B_2 = 2$; $N = 5$, $\langle \cdot, \cdot \rangle_X := \langle \cdot, \cdot \rangle_{H_0^1}$,

$$S_N = \{0.1, 0.5, 0.9, 1.4, 1.7\} \times \{0.1\}^3 \subseteq \mathbb{R}^4$$

Erkenntnisse:

- Fehlerschätzer kann günstig für sehr feines Parametergitter berechnet werden, Fehler ist teuer zu berechnen, daher nur in wenigen Punkten.
- Fehler und Schätzer sind 0 für Basisparameter (bestätigt 3.8, 3.14).
- Fehlerschätzer ist obere Schranke für Fehler gemäß 3.13.
- Für kleine Werte von μ_1 größere Fehler \Rightarrow gute Wahl von S_N wird vermutlich (und später bewiesen) hier mehr Samples benötigen.

demos__chapter3(2) Effektivitäten $\eta_N(\mu)$ und obere Schranke $\frac{\gamma}{\alpha} \leq \frac{\mu_{max}}{\mu_{min}}$.
Erkenntnisse:

- Effektivitäten sind gut, nur etwa Faktor 10 über Fehler.
- Obere Schranke für Effektivität gemäß 3.16.
- Effektivitäten sind undefiniert für Parametersamples $\mu \in S_N$ (Division durch Null).

demos__chapter3(3) Fehlerkonvergenz bezüglich N .

$$B_1 = B_2 = 3, \quad \mu_1 \in [0.5, 2], \quad \mu = (\mu_1, 1, \dots, 1) \in \mathbb{R}^9$$

Lagrange-Basis mit Gram-Schmidt-Orthonormierung, $\{\mu_i\}_{i=1}^N$ äquidistant. Erkenntnisse für Testfehler: (Maximierung über 100 zufällige Parameter)

$$S_{test} \subset \mathcal{P}, \quad |S_{test}| = 100$$

- Exponentielle Konvergenz für Fehler und Schätzer.
- Obere Schranke sehr gut.
- Numerische Ungenauigkeiten für Schätzer.

3.3 Offline/Online-Zerlegung

Bisher:

- $(P_N(\mu))$ niedrigdimensional, aber noch keine schnelle Berechnungsvorschrift.
- Um “berechenbares” Verfahren zu erhalten: Forderung $\dim X < \infty$ in diesem Kapitel.
- Für effiziente Berechnung ist separierbare Parameterabhängigkeit von $(P(\mu))$ essenziell.

Offline-Phase:

- Typischerweise berechnungsintensiv, Komplexität polynomiell in $H := \dim X$

- Einmal durchgeführt.
- Berechnung *hochdimensionaler* Daten: Snapshots, reduzierte Basis, Riesz-Repräsentanten. (“detailed_data” in RBmatlab)
- Projektion der hochdimensionalen Daten in *parameterunabhängigen niedrigdimensionalen* Daten. (“reduced_data”)

Online-Phase:

- Schnelle Berechnung, Komplexität polynomiell in N , Q_a , Q_f , Q_l , *unabhängig von* H .
- Typischerweise häufig ausgeführt für variierendes μ .
- Assemblierung des reduzierten parametrischen Systems für $(P_N(\mu))$.
- Lösen von $(P_N(\mu))$.
- Berechnung von Fehlerschranken und Effektivität.

Komplexitätsbetrachtung der bisherigen Formulierung

- Mit $\dim X = H$ und dünnbesetzter Matrix für $(P(\mu))$ ist Lösung z.B. in $\mathcal{O}(H^2)$ erreichbar (z.B. H Schritte eines iterativen Löser mit $\mathcal{O}(H)$ Komplexität für Matrix-Vektor-Multiplikation dank Dünnbesetztheit).
- $N \times N$ System für $(P_N(\mu))$ ist vollbesetzt, also in $\mathcal{O}(N^3)$ lösbar, also $N \ll H$ erforderlich, um Gewinn zu bewirken.
- Genaue Betrachtung der Berechnung von $u_N(\mu)$:
 1. N Snapshots berechnen mittels $(P(\mu))$: $\mathcal{O}(N \cdot H^2)$
 2. N^2 Auswertungen von $a(\varphi_i, \varphi_j; \mu)$: $\mathcal{O}(N^2 \cdot H)$
 3. N Auswertungen von $f(\varphi_i; \mu)$: $\mathcal{O}(N \cdot H)$
 4. Lösen des $N \times N$ Systems für $(P_N(\mu))$: $\mathcal{O}(N^3)$
- Wir haben noch keine Offline/Online-Zerlegung: 1. gehört zur Offline-Phase, 4. gehört zur Online-Phase, aber 2. und 3. können nicht in Offline-Phase berechnet werden (wegen Parameterabhängigkeit) und nicht in Online-Phase (wegen H -Abhängigkeit).
→ Zerlegung von 2. und 3. mittels separierbarer Parameterabhängigkeit

Definition 3.19 (Notation für Zerlegung von $(P(\mu))$)

Unter Annahme $H = \dim X < \infty$, $X = \text{span} \{\psi_i\}_{i=1}^H$, definiere Matrix

$$K := (\langle \psi_i, \psi_j \rangle)_{i,j=1}^H \in \mathbb{R}^{H \times H} \quad \text{“Gram’sche Matrix” / “Skalarprodukt-Matrix”}$$

Mit separierbare Parameterabhängigkeit definiere Matrizen und Vektoren

$$\begin{aligned} A^q &:= (a^q(\psi_j, \psi_i))_{i,j=1}^H \in \mathbb{R}^{H \times H}, & q &= 1, \dots, Q_a \\ \underline{f}^q &:= (f^q(\psi_i))_{i=1}^H \in \mathbb{R}^H, & q &= 1, \dots, Q_f \\ \underline{l}^q &:= (l^q(\psi_i))_{i=1}^H \in \mathbb{R}^H, & q &= 1, \dots, Q_l \end{aligned}$$

Korollar 3.20 (Lösung von $(P(\mu))$)

Lösung von $(P(\mu))$ wird erhalten durch Assemblieren des vollen Systems

$$A(\mu) = \sum_{q=1}^{Q_a} \Theta_a^q(\mu) \cdot A^q, \quad \underline{f}(\mu) = \sum_{q=1}^{Q_f} \Theta_f^q(\mu) \underline{f}^q, \quad \underline{l}(\mu) = \sum_{q=1}^{Q_l} \Theta_l^q(\mu) \underline{l}^q$$

und Lösen von $A(\mu) \underline{u}(\mu) = \underline{f}(\mu)$ nach $\underline{u}(\mu) = (u_i)_{i=1}^H \in \mathbb{R}^H$ und

$$u(\mu) = \sum_{i=1}^H u_i \varphi_i \in X, \quad s(\mu) = \underline{l}^T(\mu) \cdot \underline{u}(\mu)$$

Beweis. Klar mit Definitionen. □

Bemerkung.

- Das Vorliegen der $A^q, \underline{f}^q, \underline{l}^q$ ist nicht trivial im Fall von “fremden” Diskretisierungspaketen und stellt wesentliche Schwierigkeit in breiter praktischer Anwendung dar. Motivation für Eigenentwicklung von Diskretisierungscode.
- Sinn von Matrix K ist Berechnung von Skalarprodukten und Normen, z.B. für

$$\begin{aligned} u &= \sum u_i \psi_i, \quad v = \sum v_i \psi_i \in X \quad \text{für} \quad \underline{u} = (u_i), \underline{v} = (v_i)_{i=1}^H \in \mathbb{R}^H \\ &\Rightarrow \langle u, v \rangle_X = \sum_{i,j} u_i v_j \langle \psi_i, \psi_j \rangle = \underline{u}^T K \underline{v} \end{aligned}$$

Korollar 3.21 (Offline-/Online- Zerlegung für $(P_N(\mu))$)

(Offline:) Nach Konstruktion einer Basis $\Phi_N = \{\varphi_1, \dots, \varphi_N\}$ berechne parameter-unabhängige Komponenten-Matrizen & Vektoren

$$A_N^q := (a^q(\varphi_j, \varphi_i))_{i,j=1}^N \in \mathbb{R}^{N \times N}, \quad q = 1, \dots, Q_n$$

$$\underline{f}_N^q := (f^q(\varphi_i))_{i=1}^N, \quad \underline{l}_N^q := (l^q(\varphi_i))_{i=1}^N \in \mathbb{R}^N, \quad q = 1, \dots, Q_f/Q_l$$

(Online:) Zu $\mu \in \mathcal{P}$ berechne Koeffizienten $\Theta_a^q(\mu), \Theta_f^q(\mu), \Theta_l^q(\mu)$ und

$$A_N(\mu) := \sum_q \Theta_a^q(\mu) A_N^q$$

$$\underline{f}_N(\mu) := \sum_q \Theta_f^q(\mu) \underline{f}_N^q, \quad \underline{l}_N(\mu) := \sum_q \Theta_l^q(\mu) \underline{l}_N^q$$

Dies liefert genau das diskrete System $A_N(\mu) \underline{u}_N = \underline{f}_N(\mu)$ aus 3.6 welches nach \underline{u}_N gelöst wird und $u_N(\mu), s_N(\mu)$ ergibt

Beweis. klar wg. Separierbarkeit □

Bemerkung (Einfache Berechnung von $A_N^q, \underline{f}_N^q, \underline{l}_N^q$). Die reduzierten Komponenten benötigen keinerlei Integration über Ω oder Gitterdurchlauf, falls hochdim. A^q vorliegen. Sei Basis Φ_N gegeben durch Koeffizientenmatrix

$$\Phi_N := (\varphi_{ji})_{i=1, j=1}^H, N \in \mathbb{R}^{N \times N} \quad \text{mit} \quad \varphi_j = \sum_{i=1}^H \varphi_{ji} \psi_i$$

Dann erhalte reduzierten Komponenten durch Matrix-Multi

$$A_N^q := \Phi_N^T A^q; \underline{f}_N^q := \Phi_N^T \underline{f}^q; \underline{l}_N^q := \Phi_N^T \underline{l}^q$$

Bemerkung.

- Offline-Phase benötigt $\mathcal{O}(NH^2 + NH(Q_f + Q_l) + N^2 H Q_a)$ für die Berechnung von $\Phi_N, \underline{f}_N^q, \underline{l}_N^q, A_N^q$ dominiert von der Basisgenerierung.
- Online-Phase skaliert mit $\mathcal{O}(N^2 Q_a + N(Q_f + Q_l) + N^3)$ für Berechnung von $A_N(\mu), \underline{f}_N(\mu), \underline{l}_N(\mu)$ und $\underline{u}_N(\mu)$ dominiert durch LGS lösen falls Q_a, Q_f, Q_l klein sind. Insbesondere komplett unabhängig von H , wie gewünscht.
- Laufzeitdiagramm Seien $t_{detail}, t_{offline}, t_{online}$, die Laufzeiten für einzelne Lösungen von $(P(\mu))$, Offline-Phase bzw. Online-Phase von $(P_N(\mu))$. Unter Annahme, dass diese konstant unter Parametervariation, erhalte affin-lineare Beziehung der Gesamtlaufzeit für k parameterische Lösungen

$$t(k) := k \cdot t_{detail}, \quad t_N(k) = t_{offline} + k \cdot t_{online}$$

Das reduzierte Modell zahlt sich aus, sobald mehr als $k^* := \frac{t_{offline}}{t_{detail} - t_{online}}$ Lösungen berechnet werden sollen.




Abbildung 6: Laufzeiten mit wachsender Anzahl an Simulationen.
(aus B. Haasdonk, Reduzierte-Basis-Methoden, Skript zur Vorlesung SS 2011, Universität Stuttgart, IANS-Report 4/11, 2011.)

Bemerkung (Keine Unterscheidung zwischen u und u_h). Erinnerung: Wir unterscheiden (meistens) nicht in Notation zwischen u_h (FEM-Lösung) und u (Sobolev-Raum Lösung). Dies kann nun begründet werden:

- i) Die Online-Phase ist unabhängig von $H = \dim(X)$, daher kann H beliebig groß und damit u_h beliebig präzise gemacht werden durch geeignete Diskretisierung mit genügend feinem Gitter, so dass u und u_h praktisch ununterscheidbar sind ($\|u - u_h\|$ beliebig klein aber $(P_N(\mu))$ schnell lösbar).
- ii) In der Praxis wird Reduktionsfehler den Gesamtfehler dominieren, der (FEM-)Diskretisierungsfehler spielt untergeordnete Rolle.

$$\epsilon := \|u - u_h\| \ll \|u_h - u_N\|$$

$$\Rightarrow \|u_h - u_N\| - \epsilon \leq \underbrace{\|u - u_N\|}_{\text{theoretisch das Ideal}} \leq \overbrace{\|u_h - u_N\|}^{\text{berechenbar}} + \epsilon$$

also kontrollieren wir durch Fehlerschranken für $\|u_h - u_N\|$ bis auf ϵ auch den eigentlich interessanten Fehler $\|u - u_N\|$.

3.4 Offline-/Online- Zerlegung für Fehlerschranken/Effektivitätsschranken

Für schnelle Berechnung der Fehlerschranken & Effektivitätsschranken benötigen wir Zerlegung für

- Duale Norm des Residuums $\|r(\cdot; \mu)\|_{X'} = \|v_r\|$ für alle Fehlerschranken
- Duale Norm des Ausgabefunktional $\|l(\cdot; \mu)\|_{X'}$ für $\Delta_{N,s}(\mu)$
- Norm $\|u_N(\mu)\|_X$ der RB-Lösung für relativen Energienormfehlerschätzer $\Delta_N^{en,rel}$.
- Untere/obere Schranke $\alpha_{LB}(\mu)$ bzw. $\gamma_{UB}(\mu)$ für Koerzivitäts- bzw. Stetigkeitskonstante für Fehlerschätzer bzw. Effektivitätsschranken.

Separierbarkeit von $(P(\mu))$ überträgt sich auf Residuum

Satz 3.22 (Separierbare Parameter-Abhängigkeit für $r(\cdot; \mu)$)

Seien a, f sep. parametrisch. Nach Riesz existieren $v_f^q \in X$ mit $\langle v_f^q, v \rangle = f^q(v) \forall v \in X, q = 1, \dots, Q_f$ und $v_a^{q,n} \in X$ mit $\langle v_a^{q,n}, v \rangle = a^q(\varphi_n, v), v \in X, q = 1, \dots, Q_a, n = 1, \dots, N$ Setze $Q_r := NQ_a + Q_f$ und Aufzählung von $\{v_a^{q,n}, v_f\}$ durch

$$(v_r^1, \dots, v_r^{Q_r}) := (v_f^1, \dots, v_f^{Q_f}, v_a^{1,1}, \dots, v_a^{Q_a,1}, v_a^{1,2}, \dots, v_a^{Q_a,2}, \dots, v_a^{Q_a,N})$$

Für $\mu \in \mathcal{P}$ sei $u_N = \sum_{n=1}^N u_{Nn} \varphi_n$ Lösung von $(P_N(\mu))$ und hiermit definiere

$$(\Theta_r^1(\mu), \dots, \Theta_r^{Q_r}(\mu)) := (\Theta_f^1(\mu), \dots, \Theta_f^{Q_f}(\mu), -\Theta_a^1(\mu), \dots, -\Theta_a^{Q_a}(\mu)u_{N1}, -\Theta_a^1(\mu)u_{N2}, \dots, -\Theta_a^{Q_a}(\mu)u_{N2}, \dots, -\Theta_a^{Q_a}(\mu)u_{NN})$$

Mit $r^q(\cdot) := \langle v_r^q, \cdot \rangle \in X'$, $q = 1, \dots, Q_r$ sind $r(\cdot; \mu)$ und $v_r(\mu)$ separierbar parametrisch via

$$r(\cdot; \mu) = \sum_{q=1}^{Q_r} \Theta_r^q(\mu) \cdot r^q(\cdot), \quad v_r(\mu) = \sum_{q=1}^{Q_r} \Theta_r^q(\mu) \cdot v_r^q \quad \forall \mu \in \mathcal{P}$$

Beweis. Definition und Linearität ergibt:

$$\begin{aligned} \langle v_r(\mu), v \rangle &= r(v; \mu) = f(v; \mu) - a(u_N(\mu), v; \mu) \\ &= \sum_q \Theta_f^q(\mu) f^q(v) - \sum_q \sum_n \Theta_a^q(\mu) u_{Nn} a^q(\varphi_n, v) \\ &= \underbrace{\left\langle \sum_q \Theta_f^q(\mu) v_f^q - \sum_q \sum_n \Theta_a^q(\mu) u_{Nn} v_a^q, v \right\rangle}_{\sum \Theta_r^q(\mu) v_r^q} \\ &= \sum_{q=1}^{Q_r} \Theta_r^q(\mu) r^q(v) \quad \forall v \in X \end{aligned}$$

□

Offensichtlich Berechnung von Riesz-Repräsentant notwendig, dies geschieht durch Ausnutzen der Endlichdim. von $X = \text{span}\{\psi_i\}_{i=1}^H$ und $K := (\langle \psi_i, \psi_j \rangle)_{i,j=1}^H$

Satz 3.23 (Berechnung von Riesz-Repr.)

Für $g \in X'$ erhält man Koeffizientenvektor $\underline{v} = (v_i)_{i=1}^H \in \mathbb{R}^H$ seines Riesz-Repräsentanten $v_g = \sum_{i=1}^H v_i \psi_i \in X$ durch lösen von

$$K \underline{v} = \underline{g} \quad (3.5)$$

mit Vektor $\underline{g} := (g(\psi_i))_{i=1}^H \in \mathbb{R}^H$

Beweis. Für jedes $u = \sum_{i=1}^H u_i \psi_i \in X$ mit Koeffizientenvektor $\underline{u} = (u_i)_{i=1}^H$ erhalten wir

$$g(u) = g\left(\sum u_i \psi_i\right) = \sum u_i g(\psi_i) = \underline{u}^T \underline{g} \stackrel{3.5}{=} \underline{u}^T K \underline{v} = \langle u, v_g \rangle$$

□

Bemerkung. 3.5 ist typischerweise dünn besetzt, also mit iterativen LGS-Lösern berechenbar.

Korollar 3.24 (Offline-/Online- für Residuen-Norm)

(Offline:) Nach Offline von $(P_N(\mu))$ gemäß 3.21 def. $G_r := (r^q(v_r^{q'}))_{q,q'=1}^{Q_r} \in \mathbb{R}^{Q_r \times Q_r}$ mittels Residuen-Komponenten r^q und Riesz-Repr. v_r^q aus 3.22 (Online:) Für $\mu \in \mathcal{P}$ und RB-Lösung $\underline{u}_N \in \mathbb{R}^N$ berechne Residuen-Koeff-Vektor $\underline{\Theta}_r(\mu) = (\Theta_r^1(\mu), \dots, \Theta_r^{Q_r}(\mu))^T \in \mathbb{R}^{Q_r}$. Dann gilt:

$$\|v_r(\mu)\|_X = \|r(\cdot; \mu)\|_X = \sqrt{\underline{\Theta}_r(\mu)^T \cdot G_r \underline{\Theta}_r(\mu)} \quad (3.6)$$

Beweis. Zunächst sehen wir $G_r = (\langle v_r^q, v_r^{q'} \rangle)_{q,q'=1}^{Q_r}$. Isometrie der Riesz-Abbildung & Separierbarkeit ergeben

$$\|r(\mu)\|_X^2 = \|v_r(\mu)\|_X^2 = \left\langle \sum_{q=1}^{Q_r} \Theta_r^q(\mu) v_r^q, \sum_{q'=1}^{Q_r} \Theta_r^{q'}(\mu) v_r^{q'} \right\rangle = \underline{\Theta}_r^T \cdot G_r \cdot \underline{\Theta}_r(\mu)$$

□

Bemerkung (Stabilisierung durch Orthonormierung von $\{v_r^q\}$). Wie in `demos_chapter3(3)` gesehen, existiert eine Genauigkeitsgrenze für Fehlerschätzer, diese liegt in numerischen Auslöschungseffekten in 3.6 begründet, denn G_r ist potentiell schlecht konditioniert. Gemäß einer Idee von Behr & Rave 2014 lässt sich die Genauigkeit steigern, indem die $\{v_r^q\}$ orthonormiert werden und 3.6 mit entsprechender Transformationsmatrix modifiziert werden.

Korollar 3.25 (Offline-/Online- Zerlegung für $\|l(\cdot; \mu)\|_{X'}$)
(Offline:) Berechne Riesz-Repr. $v_l^q \in X$ der Ausgabekomponenten, d. h.

$$\langle v_l^q, v \rangle = l^q(v) \quad \forall v \in X, q = 1, \dots, Q_l$$

und def. $G_l := (l^q(v_l^{q'}))_{q,q'=1}^{Q_l}$ (Online:) Zu $\mu \in \mathcal{P}$ berechne $\underline{\Theta}_l(\mu) := (\Theta_l^1(\mu), \dots, \Theta_l^{Q_l}(\mu))$
und $\|l(\cdot; \mu)\|_{X'} = \sqrt{\underline{\Theta}_l^T G_l \underline{\Theta}_l}$

Beweis. analog zu 3.24

□

Korollar 3.26 (Offline-/Online für $\|u_N(\mu)\|_X, \|u_N(\mu)\|_\mu$)
(Offline:) Nach der Offline-Phase von $(P_N(\mu))$ def.

$$K_N := (\langle \varphi_i, \varphi_j \rangle)_{i,j=1}^N \in \mathbb{R}^{N \times N}$$

(Online:) Zu $\mu \in \mathcal{P}$ berechne $A_N(\mu)$ und $\underline{u}_N(\mu)$ durch Online-Phase von $(P_N(\mu))$

$$\|u_N(\mu)\|_X = \sqrt{\underline{u}_N^T K_N \underline{u}_N}$$

$$\|u_N(\mu)\|_\mu = \sqrt{\underline{u}_N^T \left(\frac{1}{2} (A_N(\mu) + A_N(\mu)^T) \right) \underline{u}_N}$$

Beweis.

$$\|u_N\|^2 = \left\langle \sum_n u_{Nn} \varphi_n, \sum_{n'} u_{Nn'} \varphi_{n'} \right\rangle = \sum_{n,n'} u_{Nn} u_{Nn'} \langle \varphi_n, \varphi_{n'} \rangle = \underline{u}_N^T \cdot K_N \cdot \underline{u}_N$$

analog für Energienorm mit $A_{N,s} := \frac{1}{2} (A_N(\mu) + A_N(\mu)^T)$

□

Bemerkung. K_N wieder einfach aus K berechenbar (Übung).

Für Fehlerschranken fehlen noch untere Schranke $\alpha_{LB}(\mu) \leq \alpha(\mu)$, welche schnell berechenbar sein sollen. Falls $a(\cdot, \cdot; \mu)$ glm. koerziv bzgl. μ und $\bar{\alpha} < 0$ bekannt, so ist $\alpha_{LB}(\mu) := \bar{\alpha}$ gültige Wahlmöglichkeit. In gewissen Fällen kann eine größere und damit bessere Schranke angegeben werden.

Satz 3.27 (“Min- Θ -Verfahren” zur Berechnung von $\alpha_{LB}(\mu)$)

Seien $a^q(u, u) \geq 0 \forall q, u$ und $\Theta_a^q(\mu) > 0 \forall \mu$

(Offline:) Sei $\alpha(\bar{\mu})$ für ein $\bar{\mu} \in \mathcal{P}$ verfügbar

(Online:) Setze für $\mu \in \mathcal{P}$

$$\alpha_{LB}(\mu) := \alpha(\bar{\mu}) \cdot \min_q \frac{\Theta_a^q(\mu)}{\Theta_a^q(\bar{\mu})}$$

Dann gilt $0 < \alpha_{LB}(\mu) \leq \alpha(\mu)$

Beweis. Wegen $0 < \alpha(\bar{\mu})$ und $0 < c(\mu) := \min_q \frac{\Theta_a^q(\mu)}{\Theta_a^q(\bar{\mu})}$ gilt $0 < \alpha(\bar{\mu}) \cdot c(\mu) := \alpha_{LB}(\mu)$

Folgende Argumentation ähnlich zu 2.6 ii)

Für alle $u \in X$ gilt

$$\begin{aligned} a(u, u; \mu) &= \sum_q \Theta_a^q(\mu) a^q(u, u) = \sum_q \frac{\Theta_a^q(\mu)}{\Theta_a^q(\bar{\mu})} \cdot \Theta_a^q(\bar{\mu}) a^q(u, u) \\ &\geq \sum_q \underbrace{\left(\min_{q'} \frac{\Theta_a^{q'}(\mu)}{\Theta_a^{q'}(\bar{\mu})} \right)}_{c(\mu)} \cdot \Theta_a^q(\bar{\mu}) a^q(u, u) \\ &= c(\mu) \cdot \underbrace{\sum_q \Theta_a^q(\bar{\mu}) a^q(u, u)}_{=a(u, u; \bar{\mu})} = c(\mu) a(u, u; \bar{\mu}) \\ &\stackrel{\text{glm. koerziv bzgl } \mu}{\geq} c(\mu) \cdot \alpha(\bar{\mu}) \cdot \|u\|^2 \\ &= \alpha_{LB}(\mu) \cdot \|u\|^2 \end{aligned}$$

Also insbesondere

$$\alpha(\mu) = \inf_u \frac{a(u, u; \mu)}{\|u\|^2} \geq \alpha_{LB}(\mu)$$

□

Bemerkung.

- “Min- Θ ” kann für Thermischen Block angewandt werden
- obiges gilt auch für nichtsymm. $a(\cdot, \cdot)$
- $\alpha(\bar{\mu})$ kann mittels eines hochdimensionalen Eigenwertproblems bestimmt werden:

Satz 3.28 (Berechnung von $\alpha(\mu)$ für $(P(\mu))$)

Seien $A(\mu)$, $K \in \mathbb{R}^{H \times H}$ wie in 3.19/3.20.

Setze $A_s(\mu) := \frac{1}{2}(A(\mu) + A(\mu)^T)$. Dann gilt

$$\alpha(\mu) = \lambda_{\min}(K^{-1}A_s(\mu))$$

wobei λ_{\min} den kleinsten Eigenwert bezeichnet.

Beweis. Sie $K = LL^T$ (z. B. Cholesky oder Matrix-Wurzel) und verwende $\underline{v} = L^t \underline{u}$:

$$\begin{aligned} \alpha(\mu) &= \inf_{u \in X} \frac{a(u, u; \mu)}{\|u\|^2} = \inf_{\underline{u} \in \mathbb{R}^H} \frac{\underline{u}^T A(\mu) \underline{u}}{\underline{u}^T K \underline{u}} \\ &= \inf_{\underline{u} \in \mathbb{R}^H} \frac{\underline{u}^T A_s(\mu) \underline{u}}{\underline{u}^T K \underline{u}} \\ &= \inf_{\underline{v} \in \mathbb{R}^H} \frac{\underline{v}^T L^{-1} A_s \overbrace{L^{-T}}^{\text{inv. transp.} - 1 \cdot T} \underline{v}}{\underline{v}^T L^{-1} L L^T L^{-T} \underline{v}} = \inf_{\underline{v} \in \mathbb{R}^H} \frac{\underline{v}^T L^{-1} A_s L^{-T} \underline{v}}{\underline{v}^T \underline{v}} \end{aligned}$$

Also ist $\alpha(\mu)$ Minimum eines Rayleigh-Quotienten, also kleinster Eigenwert der symmetrischen & positiv definiten Matrix $\bar{A}_s := L^{-1} A_s L^{-T}$

Die Matrizen \bar{A}_s und $K^{-1} A_s$ sind ähnlich, da

$$L^T (K^{-1} A_s) L^{-T} = L^T L^{-T} L^{-1} A_s L^{-T} = L^{-1} A_s L^{-T} = \bar{A}_s$$

Also haben sie identische Eigenwerte. □

Bemerkung.

- Inversion von K muss verhindert werden. Daher verwende EW-Löser, welcher nur Matrix-Vektor-Multiplikation verwendet. Sobald ein Produkt $y = K^{-1} A_s x$ erforderlich ist, löst man das System $Ky = A_s x$. Alternativ kann auch kleinster EW eines verallgemeinerten EWP $A_s \underline{u} = \lambda K \underline{u}$ berechnet werden.
- Für variationelle Form des verallg. EWP für ∞ -dim $(P(\mu))$ siehe Patera & Rozza
- Für Probleme, bei denen die Voraussetzungen von Min- Θ nicht erfüllt sind, kann "Successive Constraint Method" (SCM) eine Alternative darstellen. \rightsquigarrow §??

Satz 3.29 ("Max- Θ "-Verfahren für $\gamma_{UB}(\mu)$, symmetrisches $a(\cdot, \cdot)$)

Sei a symmetrisch, koerziv, separierbar parametrisch mit a^q positiv semidefinit und $\Theta_a^q > 0 \forall q, u$

(Offline:) Sei $\bar{\mu} \in \mathcal{P}$ und $\gamma(\bar{\mu})$ berechnet

(Online:) Setze für $\mu \in \mathcal{P} : \gamma_{UB}(\mu) := \gamma(\bar{\mu}) \max_q \frac{\Theta_a^q(\mu)}{\Theta_a^q(\bar{\mu})}$. Dann gilt

$$\gamma_{UB}(\mu) \leq \gamma_{UB}(\mu) < \infty$$

Beweis. Übung. □

Bemerkung (Komplexitäten). Durch die angegebenen Berechnungsverfahren ist vollständige Offline-/Online-Zerlegung der RB-Lösung, Fehlerschranken und Effektivitätsschranken erreicht (Offline unabh. von μ , Online unabh. von H). Komplexitäten für $\Delta_N(\mu), \Delta_{N,s}(\mu)$:

- Offline: $\mathcal{O}(H^3 + H^2(Q_f + Q_l + NQ_a) + HQ_l^2 + H(Q_f + NQ_a)^2)$ für EWP für $\alpha(\bar{\mu})$, Riesz-Repräsentanten für $f^q, l^q, a^q(\varphi_n, \cdot)$ und Matrix G_l und G_r
- Online: $\mathcal{O}((Q_f + NQ_a)^2 + Q_l^2 + Q_a)$ für Berechnung von $\|v_r(\cdot; \mu)\|$, $\|l(\cdot; \mu)\|_{X'}$ und $\alpha_{LB}(\mu)$ durch Min- Θ . Problematisch ist quadratische Abhängigkeit von Q_f, Q_l, NQ_a , welches diese Größen in der Praxis stark einschränkt.

demos_chapter3(4) Beispiel-Lauf von Reduktionsschritten in RBmatlab.

- Vorteilhafte Eigenschaften einer Basis Φ_N : orthogonal für numerische Stabilität, Hierarchie, so dass Basisvektoren nach Relevanz geordnet sind, d.h. $(X_{N'})_{N'=1}^N$, $X_{N'} = \text{span}\{\varphi_1, \dots, \varphi_{N'}\}$ soll Sequenz von “optimalen” Räumen sein, damit durch Variation von N' eine Fehlerkontrolle erlaubt.
- Probleme (3.7), (3.8) stellen schwierige nichtlineare Optimierungsprobleme dar. Um zu praktischer Basisgenerierung zu kommen, werden verschiedene Vereinfachungen gemacht:
 - “Snapshotbasierte” Räume: Statt $Y \subset X$ beliebig, wird $Y = \text{span}\{u(\mu^i)\}_{i=1}^N$ mit unbekanntem $\{\mu^i\}_{i=1}^N$ gesucht.
 - “Diskretisierung des Parameterraumes”. Statt $\mu \in \mathcal{P}$ wird Maximum bzw. Mittelung nur über $\mu \in \mathcal{S}_{train}$ durchgeführt, wobei $\mathcal{S}_{train} = \{\mu^i\}_{i=1}^n \subset \mathcal{P}$ endliche Menge von Trainingsparametern μ (z. B. Punkte eines äquidistanten Gitters oder zufällig gewählte Parameter oder mittels adaptiven Verfahren gewählt).
 - Statt eines Fehlermaßes, welches echte Lösung $u(\mu)$ erfordert, wird häufig ein Fehlerschätzer gewählt, welcher sehr viel schneller auswertbar ist.
 - Das resultierende vereinfachte Optimierungsproblem kann approximativ minimiert werden, indem statt simultan über $\{\mu^i\}_{i=1}^N$ zu optimieren, einzelne Basisvektoren der Reihe nach durch Optimierung bestimmt werden (“Greedy-Verfahren”)

Definition 3.30 (Kolmogorov n -Weite)

Sei $\mathcal{M} \subseteq X$ kompakte Teilmenge. Zu einem abgeschlossenen Unterraum $Y \subseteq X$ nennen wir

$$d(Y, \mathcal{M}) := \sup_{v \in \mathcal{M}} \inf_{w \in Y} \|v - w\| = \sup_{v \in \mathcal{M}} \|v - P_Y v\|$$

den *Abstand* von Y zu \mathcal{M} . Für $n \in \mathbb{N}$ nennen wir

$$d_n(\mathcal{M}) := \inf_{Y \subset X, \dim(Y)=n} d(Y, \mathcal{M})$$

die *Kolmogorov n -Weite* der Menge \mathcal{M} . Als Abschwächung definieren wir

$$\bar{d}_n(\mathcal{M}) := \inf_{Y \subset \text{span}(\mathcal{M}), \dim(Y)=n} d(Y, \mathcal{M}).$$

Bemerkung.

- d_n, \bar{d}_n fallen monoton.
- d_n, \bar{d}_n sind rein approximationstheoretische Maße, deren Abfall die Approximierbarkeit von \mathcal{M} mit linearen Unterräumen charakterisiert, unabhängig von der RB-Approximation
- Wenn wir für ein $(\mathcal{P}(\mu))$ Konvergenz oder sogar Konvergenzrate von $d_n(\mathcal{M})$ zeigen können, so erhalten wir ebenso Konvergenz mit mind derselben Rate via Céa 3.9 für die RB-Approximation

$$\|u(\mu) - u_N(\mu)\| \leq \frac{\gamma(\mu)}{\alpha(\mu)} \underbrace{\inf_{v \in X_N} \|u(\mu) - v\|}_{d(X_N, \mathcal{M})} \leq \frac{\bar{\gamma}}{\bar{\alpha}} d_n(\mathcal{M})$$

- Beziehung d_n zu \bar{d}_n . Es gilt trivialerweise

$$d_0(\mathcal{M}) = \bar{d}_0(\mathcal{M}) = d(0, \mathcal{M}) = \sup_{v \in \mathcal{M}} \|v\|,$$

$$d_n(\mathcal{M}) \leq \bar{d}_n(\mathcal{M}) \quad \forall n \in \mathbb{N},$$

falls $n_0 := \dim(\text{span}(\mathcal{M})) < \infty$, $d_n(\mathcal{M}) = \bar{d}_n(\mathcal{M}) = 0 \quad \forall n \geq n_0$

- Präzise Werte für d_n sind selten bekannt. Für endliche Menge oder Einheitskugeln können aber exakte Werte der Schranken für d_n angegeben werden.
- Beispiel: $\mathcal{M} := \{v \in X \mid \|v\| \leq 1\}$ erfüllt $d_n(\mathcal{M}) = \bar{d}_n(\mathcal{M}) = 1$ für alle $n < \dim(X)$ und $d_n(\mathcal{M}) = \bar{d}_n(\mathcal{M}) = 0$ für $n \geq \dim(X)$.
- Beispiel: $\mathcal{M} := [1, 1]^m \subset X := \mathbb{R}^m$ erfüllt $d_n(\mathcal{M}) = \bar{d}_n(\mathcal{M}) = \sqrt{mn}$ für alle $n \leq m$ und $d_n(\mathcal{M}) = \bar{d}_n(\mathcal{M}) = 0$ für $n \geq m$.
- Beispiel: “Müsli-Schachtel”: $\mathcal{M} := \prod_{i \in \mathbb{N}} [-2^i, 2^i] \subseteq l_2 \Rightarrow d_n(\mathcal{M}) \leq C \cdot 2^{-n}$, exponentielle Konvergenz

Definition 3.31 (Gram-Matrix)

Zu $\{u_i\}_{i=1}^n \subset X$ definieren wir die *Gram-Matrix* als $K := (\langle u_i, u_j \rangle_X)_{i,j=1}^n \in \mathbb{R}^{n \times n}$

Lemma 3.32 (Eigenschaften von K)

Für K Gram-Matrix von $\{u_i\}_{i=1}^n$ gilt

- i) K ist symmetrisch und positiv semidefinit.
- ii) $\text{Rang}(K) = \dim(\text{span}\{u_i\}_{i=1}^n)$
- iii) $\{u_i\}_{i=1}^n$ linear unabhängig $\Leftrightarrow K$ positiv definit

Beweis. Übung □

Bemerkung (Geometrische Information in K). K enthält sehr viel Information der $\{u_i\}_{i=1}^n$, insbesondere kann man mittels K eine isometrische Einbettung in \mathbb{R}^n erzeugt werden, d. h. es existiert $\{x_i\}_{i=1}^n \in \mathbb{R}^n$ mit

$$\langle x_i, x_j \rangle_{\mathbb{R}^n} = \langle u_i, u_j \rangle_X$$

und

$$\|x_i - x_j\|_{\mathbb{R}^n} = \|u_i - u_j\|_X$$

Sie $K = UDU^T$ Eigenwertzerlegung mit $D = \text{diag}(\lambda_1, \dots, \lambda_n)$. Setze $(x_1, \dots, x_n) := D^{\frac{1}{2}}U^T$. Dann:

$$\begin{aligned} \langle x_i, x_j \rangle_{\mathbb{R}^n} &= [(D^{\frac{1}{2}}U^T)_{i,j}]^T [(D^{\frac{1}{2}}U^T)_{i,j}] \\ &= (UD^{\frac{1}{2}})_{i,j} (D^{\frac{1}{2}}U^T)_{i,j} \\ &= (U)_{i,j} D^{\frac{1}{2}} D^{\frac{1}{2}} (U^T)_{i,j} = (UDU^T)_{ij} = (K)_{ij} = \langle u_i, u_j \rangle_X \end{aligned}$$

und

$$\begin{aligned} \|x_i - x_j\|_{\mathbb{R}^n}^2 &= \langle x_i, x_i \rangle_{\mathbb{R}^n} - 2\langle x_i, x_j \rangle_{\mathbb{R}^n} + \langle x_j, x_j \rangle_{\mathbb{R}^n} \\ &= \langle u_i, u_i \rangle_X - 2\langle u_i, u_j \rangle_X + \langle u_j, u_j \rangle_X = \|u_i - u_j\|_X^2 \end{aligned}$$

Damit können viele lineare Operationen auf $\{u_i\}_{i=1}^n$ durch geeignete Operation mit K ausgedrückt werden. Z.B. Normberechnung in $\text{span}\{u_i\}_{i=1}^n$: (siehe auch Offline/Online für Normen)

$$v = \sum_{i=1}^n v_i u_i \quad , \quad \underline{v} = (v_i)_{i=1}^n \in \mathbb{R}^n \quad \Rightarrow \quad \|v\|_X^2 = \underline{v}^T K \cdot \underline{v}$$

3.5 Basisgenerierung

Approximation durch lineare Unterräume

Motivation für Snapshot-basierte Verfahren:

- Bestimmung eines möglichst guten X_N , welches \mathcal{M} global approximiert.

- Formulierung durch Optimierungsproblem, z.B. minimiere maximalen Fehler in Energienorm

$$\min_{\substack{Y \subseteq X \\ \dim Y = N}} \max_{\mu \in \mathcal{P}} \|u(\mu) - u_N(\mu)\|_\mu \quad (3.7)$$

oder Minimum des mittleren quadratischen Projektionsfehlers

$$\min_{\substack{Y \subseteq X \\ \dim Y = N}} \int_{\mathcal{P}} \|u(\mu) - P_Y u(\mu)\|^2 d\mu \quad (3.8)$$

oder beliebiges anderes Distanzmaß.

Wir haben bereits gesehen, dass in bestimmten Fällen fehlerfreie Approximation durch geeignete RB-Räume möglich ist

Satz 3.33 (Optimales X_N für Thermischer Block, $B_1 = 1$)

Sie $p \in \mathbb{N}$, $B_1 = 1$, $B_2 = p$, $\mu^i := (\mu_{min}, \dots, \mu_{min})^T + e_i \cdot (\mu_{max} - \mu_{min})$, $i = 1, \dots, p$. Dann ist $X_N := \text{span}(u(\mu^i))_{i=1}^p$ optimal in dem Sinne, dass

$$\inf_{v \in X_N} \|u(\mu) - v\| = \inf_{v \in X_N} \|u(\mu) - v\|_\mu = 0 \quad \forall \mu \in \mathcal{P}$$

Beweis. Übung. □

Satz 3.34 (Optimales X_N für $Q_a = 1$)

Sei $Q_a = 1$ und o.B.d.A. $a(u, v; \mu) = \Theta_a^1(\mu) a^1(u, v)$ und $\Theta_a^1(\mu) > 0$. Seien $\{\mu^i\}_{i=1}^{Q_f}$ derart, dass $\{f(\cdot; \mu^i)\}_{i=1}^{Q_f}$ linear unabhängig. Dann erfüllt der Lagrange RB-Raum $X_N = \text{span}(u(\mu^i))_{i=1}^{Q_f}$, $\dim X_N = Q_f$ und

$$\inf_{v \in X_N} \|u(\mu) - v\| = \inf_{v \in X_N} \|u(\mu) - v\|_\mu = 0 \quad \forall \mu \in \mathcal{P}$$

Beweis.

i) ✓

ii) $\text{span}\{f^q\}_{q=1}^{Q_f} = \text{span}\{f(\cdot; \mu^i)\}_{i=1}^q$

“ \supseteq ” ist klar weil $f(\cdot; \mu^i) = \sum_{q=1}^{Q_f} \Theta_f^q f^q(\cdot)$

“ $=$ ” aus Dimensionsbetrachtung

$$\dim\left(\text{span}\{f(\cdot; \mu^i)\}_{i=1}^{Q_f}\right) = Q_f$$

$$\dim\left(\text{span}\{f^q\}_{q=1}^{Q_f}\right) \leq Q_f$$

\Rightarrow folgt $\dim\left(\text{span}\{f^q\}_{q=1}^{Q_f}\right) = Q_f$ Gleichheit beider Räume

iii) Zeige nun exakte Approximation in X_N .

Zu $\mu \in \mathcal{P}$ existiert wegen ii) $c(\mu) = (c_i(\mu))_{i=1}^{Q_f}$ mit

$$f(\cdot; \mu) = \sum_{i=1}^{Q_f} c_i(\mu) f(\cdot; \mu^i) \quad (*)$$

Damit ist dann $u(\mu) := \sum c_i(\mu) \frac{\Theta_a^q(\mu^i)}{\Theta_a^q(\mu)} u(\mu^i)$ Lösung von $(P(\mu))$:

$$\begin{aligned} a(u(\mu), v; \mu) &= \Theta_a^1(\mu) a^1\left(\sum c_i(\mu) \frac{\Theta_a^1(\mu^i)}{\Theta_a^1(\mu)} u(\mu^i), v\right) \\ &= \sum c_i(\mu) \underbrace{\Theta_a^1(\mu^i) a^1(u(\mu^i), v)}_{=a(u(\mu^i), v; \mu^i)} \\ &= \sum c_i(\mu) f(v; \mu^i) \stackrel{(*)}{=} f(v; \mu) \end{aligned}$$

□

Für die folgende Aussage referenzieren wir Fink & Rheinboldt: On the Error Behavior of the Reduced Basis Technique for Nonlinear Finite Element Approximations, ZAMM, 63:21-28, 1983.

Satz 3.35 (Lokale exponentielle Konvergenz)

Sei $\mu^0 \in U \subset \mathcal{P} \subset \mathbb{R}$ und $u(\mu)$ analytisch in Umgebung U . Sei X_{k, μ^0} der Taylor-RB-Raum für $k \in \mathbb{N}$. Dann existiert ein $B_\delta(\mu^0) \subset U$ und $C > 0$, so dass

$$\inf_{v \in X_{k, \mu^0}} \|u(\mu) - v\| \leq C |\mu - \mu^0|^{k+1} \quad \forall \mu \in B_\delta(\mu^0)$$

Beweis. Taylor-Entwicklung

$$\begin{aligned} u(\mu) &= \sum_{i=0}^{\infty} \frac{\partial^i}{\partial \mu^i} u(\mu^0) \frac{1}{i!} (\mu - \mu^0)^i \\ &= \underbrace{\sum_{i=0}^k \frac{\partial^i}{\partial \mu^i} u(\mu^0) \frac{1}{i!} (\mu - \mu^0)^i}_{v_k(\mu)} + \underbrace{\sum_{i=k+1}^{\infty} \frac{\partial^i}{\partial \mu^i} u(\mu^0) \frac{1}{i!} (\mu - \mu^0)^{i-(k+1)} (\mu - \mu^0)^{k+1}}_{w_k(\mu)} \end{aligned}$$

Sei $\delta < 1$ so dass $B_\delta(\mu^0) \subset U$ und $C' := \sup_i \left\| \frac{\partial^i}{\partial \mu^i} u(\mu^0) \frac{1}{i!} \right\| < \infty$. Dann gilt für $\mu \in B_\delta(\mu)$

$$\begin{aligned} \|w_k(\mu)\| &\leq \sum_{i=k+1}^{\infty} \left\| \frac{\partial^i}{\partial \mu^i} u(\mu^0) \frac{1}{i!} \right\| \cdot |\mu - \mu^0|^{i-k+1} \leq C' \sum_{i=k+1}^{\infty} |\mu - \mu^0|^{i-(k+1)} \\ &\leq C' \frac{1}{1 - |\mu - \mu^0|} \leq C' \frac{1}{1 - \delta} =: C \end{aligned}$$

$$\inf_{v \in X_{k, \mu^0}} \|u(\mu) - v\| \leq \|u(\mu) - v_k(\mu)\| = \|w_k(\mu) \cdot (\mu - \mu^0)^{k+1}\| \leq C |\mu - \mu^0|^{k+1}$$

□

Die folgende Aussage basiert auf Maday & Patera & Turinici: Global a priori convergence theory for reduced-basis approximations of single-parameter symmetric coercive elliptic partial differential equations. C.R. Acad. Sci., Paris, Ser. 1, 335, 289-294, 2002.

Satz 3.36 (Globale exponentielle Konvergenz, $p = 1$)

Sei $\mathcal{P} = [\mu_{min}, \mu_{max}] \subset \mathbb{R}^+$ mit $\mu_{max} > 1$ genügend groß und $\mu_{min} = \frac{1}{\mu_{max}}$

$$a(u, v; \mu) = \mu a^1(u, v) + a^2(u, v)$$

mit a^1, a^2 symmetrisch positiv semidefinit und $f \in X'$ sei nicht parametrisch. Zu $N \in \mathbb{N}$, $N \geq 2$ seien

$$\mu_{min} = \mu^1 < \dots < \mu^N = \mu_{max}$$

logarithmisch äquidistant, d.h.

$$\ln(\mu^{i+1}) - \ln(\mu^i) = \frac{\ln(\mu_{max}) - \ln(\mu_{min})}{N-1} = \delta_N$$

und $X_N = \text{span} \{u(\mu^i)\}_{i=1}^N$ zugehöriger Lagrange RB-Raum. Dann existiert N_0 so dass für alle $N \geq N_0$ gilt

$$\frac{\|u(\mu) - u_N(\mu)\|_\mu}{\|u(\mu)\|_\mu} \leq \mu_{max}^2 e^{\frac{-N-1}{N_0-1}} \quad \forall \mu \in \mathcal{P} \quad (3.9)$$

Bemerkung.

- Voraussetzungen sind z.B. für einen thermischen Block mit $B_1 = 2$, $B_2 = 1$ erfüllt, wenn $\mu_2 = 1$ konstant gehalten wird und nur $\mu_1 = \mu$ variiert.
- Verallgemeinerung für $p > 1$ existiert.
- Satz 3.36 liefert sogar die exponentielle Konvergenz des Approximationsfehlers und damit der Weiten d_N, \bar{d}_N .

Korollar 3.37 (Exponentielle Konvergenz von d_N, \bar{d}_N)

Unter den Voraussetzungen von 3.36 gilt insbesondere mit $C > 0$ unabhängig von N

$$\inf_{v \in X_N} \|u(\mu) - v\| \leq C \cdot e^{\frac{-N-1}{N_0-1}} \quad \forall \mu \in \mathcal{P}, N \geq N_0$$

also für Kulmogorov N -Weite

$$d_N(\mathcal{M}) \leq C \cdot e^{\frac{-N-1}{N_0-1}} \quad \forall N \geq N_0$$

und wegen $X_N \subset \text{span}(\mathcal{M})$

$$\bar{d}_N(\mathcal{M}) \leq C \cdot e^{\frac{-N-1}{N_0-1}}$$

Beweis. Wegen Normäquivalenz und Beschränktheit von u gilt

$$\|u(\mu)\|_\mu \leq \sqrt{\gamma(\mu)} \|u(\mu)\| \leq \frac{\gamma(\mu)}{\alpha(\mu)} \|f(\mu)\| \leq C', \quad \text{mit } C' := \sup_{\mu \in \mathcal{P}} \frac{\sqrt{\gamma(\mu)}}{\alpha(\mu)} \|f(\mu)\|$$

Also folgt

$$\begin{aligned} \inf_{v \in X_N} \|u(\mu) - v\| &\leq \|u(\mu) - u_N(\mu)\| \leq \frac{1}{\sqrt{\alpha(\mu)}} \|u(\mu) - u_N(\mu)\|_\mu \cdot \frac{\|u(\mu)\|_\mu}{\|u(\mu)\|_\mu} \\ &\leq \frac{3.36}{\sqrt{\alpha(\mu)}} \cdot e^{\frac{-N-1}{N_0-1}} \leq \underbrace{\frac{C'}{\bar{\alpha}}}_{=: C} \cdot e^{\frac{-N-1}{N_0-1}} \end{aligned}$$

□

Ziel ist Beweis von 3.36, hierzu benötigen wir jedoch einige Notationen und Hilfsaussagen.

- Es sei $\dim X = H$ endlich aber beliebig groß. Man kann zeigen, dass die Konstante N_0 und Forderung an μ_{max} unabhängig von H ist.
- Logarithmische Abbildung des Parametergebiets. Es sei

$$\tau(z) = \ln(z)$$

und damit $\hat{\mu} := \tau(\mu)$, $\hat{\mu}_{min} = \tau(\mu_{min})$, $\hat{\mu}_{max} = \tau(\mu_{max}) = -\hat{\mu}_{min}$, $\hat{\mathcal{P}} := \tau(\mathcal{P})$, $\hat{u}(\hat{\mu}) := u(\tau^{-1}(\hat{\mu}))$, also $\hat{u}(\hat{\mu})$ Lösung von

$$e^{\hat{\mu}} a^1(\hat{u}(\hat{\mu}), v) + a^2(\hat{u}(\hat{\mu}), v) = f(v) \quad \forall v \in X \quad (3.10)$$

und dann $u(\mu) = \hat{u}(\tau(\mu))$.

- Es sei $\langle u, v \rangle_X := a(u, v; \mu = 1) = a^1(u, v) + a^2(u, v)$, dann ist (3.10) äquivalent zu

$$\langle \hat{u}(\hat{\mu}), v \rangle_X + (e^{\hat{\mu}} - 1) a^1(\hat{u}(\hat{\mu}), v) = f(v) \quad \forall v \in X \quad (3.11)$$

- Seien $(\Upsilon_i, \lambda_i)_{i=1}^H \in (X, \mathbb{R}^+)$ Eigenfunktionen/-werte von verallgemeinertem EWP

$$a^1(\Upsilon_i, v) = \lambda_i \langle \Upsilon_i, v \rangle_X \quad \forall v \in X \quad (3.12)$$

mit $0 \leq \lambda_1 \leq \dots \leq \lambda_H$, $\|\Upsilon_i\| = 1$ ist dann $\{\Upsilon_i\}_{i=1}^H$ ONB von X . Aus (3.12) mit $v = \Upsilon_i$ und positiver Semidefinitheit von a^2 folgt

$$1 = \langle \Upsilon_i, \Upsilon_i \rangle_X = a^1(\Upsilon_i, \Upsilon_i) + a^2(\Upsilon_i, \Upsilon_i) = \lambda_i + a^2(\Upsilon_i, \Upsilon_i)$$

$$\Rightarrow \lambda_i \in [0, 1] =: \Lambda \text{ weil } \lambda_i = 1 - a^2(\Upsilon_i, \Upsilon_i) \leq 1$$

- Aus Orthogonalität und (3.12) folgt

$$a(\Upsilon_j, \Upsilon_i; \mu) = \underbrace{\langle \Upsilon_j, \Upsilon_i \rangle}_{\delta_{ij}} + (e^{\hat{\mu}} - 1) \underbrace{a^1(\Upsilon_j, \Upsilon_i)}_{\lambda_i \delta_{ij}} = (1 - \lambda_j + \lambda_j e^{\hat{\mu}}) \delta_{ij} \quad (3.13)$$

Lemma 3.38 (Lösungsdarstellung)

Die Lösung von (3.10), (3.11) ist explizit gegeben durch

$$\hat{u}(\hat{\mu}) = \sum_{j=1}^H f_j \Upsilon_j g(\hat{\mu}, \lambda_j) \quad (3.14)$$

mit $f_j = f(\Upsilon_j)$ und $g : \hat{\mathcal{P}} \times \Lambda \rightarrow \mathbb{R}^+$ definiert durch

$$g(z, \sigma) = \frac{1}{1 - \sigma + \sigma e^z} \quad (3.15)$$

Beweis. Einsetzen von (3.14) in (3.11) liefert für Testfunktionen $v := \Upsilon_i$

$$\begin{aligned} & \left\langle \sum_j f_j \Upsilon_j g(\hat{\mu}, \lambda_j), \Upsilon_i \right\rangle_X + (e^{\hat{\mu}} - 1) a^1 \left(\sum_j f_j \Upsilon_j g(\hat{\mu}, \lambda_j), \Upsilon_i \right) \\ &= \sum_j f_j g(\hat{\mu}, \lambda_j) \left(\langle \Upsilon_j, \Upsilon_i \rangle_X + (e^{\hat{\mu}} - 1) a^1(\Upsilon_j, \Upsilon_i) \right) \\ &\stackrel{(3.13)}{=} \sum_j f_j g(\hat{\mu}, \lambda_j) (1 - \lambda_j + \lambda_j e^{\hat{\mu}}) \delta_{ij} \\ &= f_i g(\hat{\mu}, \lambda_i) \underbrace{(1 - \lambda_i + \lambda_i e^{\hat{\mu}})}_{=\frac{1}{g(\hat{\mu}, \lambda_i)}} = f_i = f(\Upsilon_i) \end{aligned}$$

also ist $\hat{u}(\hat{\mu})$ Lösung von (3.10) / (3.11). □

Bemerkung. Im obigen Beweis wird also ausgenutzt, dass die Systemmatrix bezüglich $\{\Upsilon_i\}_{i=1}^H$ diagonal ist.

Lemma 3.39 (Energienorm-Darstellung in ONB)

Mit $\mu = \tau^{-1}(\hat{\mu})$ gilt für eine Funktion $w = \sum_{i=1}^H w_i \Upsilon_i$

$$\|w\|_\mu^2 = \sum_{i=1}^H \frac{w_i^2}{g(\hat{\mu}, \lambda_i)}$$

Beweis.

$$\|w\|_\mu = a(w, w; \mu) = \sum_{i,j} w_i w_j \underbrace{a(\Upsilon_i, \Upsilon_j; \mu)}_{\stackrel{(3.13)}{=} (1 - \lambda_j + \lambda_j e^{\hat{\mu}}) \delta_{ij}} = \sum \frac{w_i^2}{g(\hat{\mu}, \lambda_i)}$$

□

Wir benötigen (grobe) Schranken für g und seinen Ableitungen bezüglich z .

Lemma 3.40 (Schranken für $g, \frac{\partial^i}{\partial z^i} g$)

Für alle $z \in \hat{\mathcal{P}}, \sigma \in \Lambda = [0,1]$ gilt

i)

$$g(z, \sigma) \in \left[\frac{1}{\mu_{max}}, \mu_{max} \right]$$

ii)

$$\frac{1}{g(z, \sigma)} \in \left[\frac{1}{\mu_{max}}, \mu_{max} \right]$$

iii)

$$\left| \frac{\partial^i}{\partial z^i} g(z, \sigma) \right| \leq \bar{C} \cdot C \cdot j! \quad \text{mit} \quad \bar{C} = \mu_{max}, C = 2\mu_{max}^2$$

Beweis. i) & ii)

$$\frac{1}{g(z, \sigma)} = 1 + \sigma(e^z - 1) \stackrel{j=1}{\leq} e^{\hat{\mu}_{max}} = \mu_{max} \quad \Rightarrow \quad g(z, \sigma) \geq \frac{1}{\mu_{max}}$$

Für festes z minimiere $\frac{1}{g(z, \sigma) = 1 + \sigma(e^z - 1)}$ bezüglich σ

$$\min_{\sigma \in [0,1]} \frac{1}{g(z, \sigma)} = \begin{cases} 1 & z = 0 \quad (\sigma \text{ beliebig}) \\ 1 & z > 0 \quad (\sigma = 0) \\ e^z & z < 0 \quad (\sigma = 1) \end{cases}$$

$$\frac{1}{g(z, \sigma)} \geq \min_{\sigma, z} \frac{1}{g(z, \sigma)} = e^{\hat{\mu}_{min}} = \mu_{min} = \frac{1}{\mu_{max}} \quad \Rightarrow \quad g(z, \sigma) \leq \mu_{max}$$

iii) Wir zeigen per Induktion, dass $\frac{\partial^i}{\partial z^i} g(z, \sigma)$ sich darstellen lässt als

$$\frac{\partial^i}{\partial z^i} g(z, \sigma) = \sum_{k=2}^{j+1} \beta_k^j \sigma^{(k-1)} e^{(k-1)z} g^k(z, \sigma), \quad j \geq 1 \quad (3.16)$$

mit

$$\left. \begin{aligned} \beta_2^1 &:= -1 \\ \beta_2^{j+1} &= \beta_2^j = -1 \\ \beta_k^{j+1} &= \beta_k^j(k-1) - \beta_{k-1}^j(k-1), \quad k = 3, \dots, j+1 \\ \beta_{j+2}^{j+1} &:= -(j+1)\beta_{j+1}^j \end{aligned} \right\} \quad (3.17)$$

Denn für $j = 1$ erhält man

$$\frac{\partial}{\partial z} g(z, \sigma) = \frac{-\sigma e^z}{(1 - \sigma - \sigma e^z)^2} = -e^z \sigma g^2(z, \sigma)$$

also mit (3.16) $\beta_2^1 = -1$.

Induktionsschritt

$$\begin{aligned}
\frac{\partial^i}{\partial z^i} g(z, \sigma) &= \frac{\partial}{\partial z} \left(\sum_{k=2}^{j+1} \beta_k^j \sigma^{(k-1)} e^{(k-1)z} g^k(z, \sigma) \right) \\
&= \sum_{k=2}^{j+1} \beta_k^j \sigma^{(k-1)} \left(e^{(k-1)z} \underbrace{\frac{\partial}{\partial z} g^k(z, \sigma)}_{=kg^{k-1}(z, \sigma)} + (k-1)e^{(k-1)z} g^k(z, \sigma) \right) \\
&= \sum_{k=2}^{j+1} \beta_k^j \sigma^{(k-1)} \left[-\sigma e^{kz} k \cdot g^{k+1}(z, \sigma) + (k-1)e^{(k-1)z} g^k(z, \sigma) \right] \\
&= \sum_{k=2}^{j+1} \beta_k^j (k-1) \sigma^{(k-1)} e^{(k-1)z} g^k(z, \sigma) + \sum_{k=3}^{j+2} \beta_{k-1}^j \sigma^{(k-1)} \cdot \left(-\sigma e^{(k-1)z} (k-1) g^k(z, \sigma) \right) \\
&= \underbrace{\beta_2^j \sigma e^z g^2(z, \sigma)}_{k=2} + \sum_{k=3}^{j+1} \left(\beta_k^j (k-1) - \beta_{k-1}^j (k-1) \right) \sigma^{(k-1)} e^{(k-1)z} g^k(z, \sigma) \\
&\quad \underbrace{- \beta_{j+1}^j (j+1) \sigma^{j+1} e^{(j+1)z} g^{j+2}(z, \sigma)}_{\text{"}k=j+2\text{"}}
\end{aligned}$$

Für $j \geq 1$ setze $S_j := \sum_{k=2}^{j+1} |\beta_k^j|$ und zeige per Induktion, dass

$$S_j \leq 2^j \cdot j! \quad j \geq 1$$

Für $j = 1$ ist $S_j = 1 \leq 2^1 \cdot 1! = 2$ also Induktionsanfang. Gelte Behauptung für $j \geq 1$. Dann gilt:

$$\begin{aligned}
|\beta_2^{j+1}| &= 1 \\
|\beta_k^{j+1}| &< (j+1)(|\beta_k^j| + |\beta_{k-1}^j|) \quad k = 3, \dots, j+1 \\
|\beta_{j+2}^{j+1}| &= (j+1)|\beta_{j+1}^j| \\
\Rightarrow S_{j+1} &= \sum_{k=2}^{j+2} |\beta_k^{j+1}| \leq 2(j+1)S_j \stackrel{i.A.}{\leq} 2(j+1)2^j \cdot j! = 2^{j+1}(j+1)!
\end{aligned}$$

Damit folgt (iii):

$$\begin{aligned}
\left| \frac{\partial^j}{\partial z^j} g(z, \sigma) \right| &= \left| \sum_{k=2}^{j+1} \beta_k^j \sigma^{(k-1)} e^{(k-1)z} g^k(z, \sigma) \right| \\
&\leq \underbrace{\left(\sum_{k=2}^{j+1} |\beta_k^j| \right)}_{\leq 2^j \cdot j!} \underbrace{\sup_k |\sigma^{(k-1)} e^{(k-1)z} g^k(z, \sigma)|}_{\leq 1 \cdot e^{j \mu_{\max}} \cdot \mu_{\max}^{j+1} = \mu_{\max} (\mu_{\max}^2)^j} \\
&\leq (2 \mu_{\max}^2)^j \cdot j! \cdot \mu_{\max}
\end{aligned}$$

□

Bemerkung. $g(\hat{\mu}, \lambda_i)$ sind gemäß 3.38 Koeffizienten für $\hat{u}(\hat{\mu})$ in ONB Entwicklung. Entsprechend sind $\frac{\partial^j}{\partial z^j} g(z, \sigma)$ für $z = \hat{\mu}$, $\sigma = \lambda_i$ die Koeffizienten der Sensitivitätsableitung $\frac{\partial^j}{\partial \hat{\mu}^j} \hat{u}(\hat{\mu})$ in der ONB Entwicklung, also impliziert Lemma 3.40 eine Beschränktheit der Sensitivitätsableitungen.

Lemma 3.41 (Darstellung von Fkt. aus X_N)

Für Koeffizientenfunktionen $\tilde{C}_n : \hat{\mathcal{P}} \rightarrow \mathbb{R}$, $n = 1, \dots, N$

$$\hat{w}_N(\hat{\mu}) := \sum_{n=1}^N \tilde{C}_n(\hat{\mu}) \hat{u}(\hat{\mu}^n)$$

mit $\hat{\mu}^n := \ln \mu^n$ ist also $\hat{w}_N(\hat{\mu}) \in X_N$. Dann lässt sich \hat{w}_N darstellen als

$$\hat{w}_N(\hat{\mu}) = \sum_{i=1}^H f_i \Upsilon_i \tilde{g}_N(\hat{\mu}, \lambda_i)$$

wobei $\tilde{g}_N(\hat{\mu}, \sigma) := \sum_{n=1}^N \tilde{C}_n(\hat{\mu}) g(\hat{\mu}^n, \sigma)$

Beweis. Aus Lösungsdarstellung 3.38 folgt

$$u(\mu^n) = \hat{u}(\hat{\mu}^n) = \sum_{i=1}^H f_i \Upsilon_i g(\hat{\mu}^n, \lambda_i), \quad n = 1, \dots, N$$

Also ist

$$\hat{w}_N(\hat{\mu}) = \sum_n \tilde{C}_n(\hat{\mu}) \sum_{i=1}^H f_i \Upsilon_i g(\hat{\mu}^n, \lambda_i) = \sum_{i=1}^H f_i \Upsilon_i \underbrace{\sum_{n=1}^N \tilde{C}_n(\hat{\mu}) g(\hat{\mu}^n, \sigma)}_{=\tilde{g}_N(\hat{\mu}, \sigma)}$$

□

Wir benötigen noch Lagrange-Interpolation in M aufeinanderfolgenden Punkten $\{\hat{\mu}^i, \dots, \hat{\mu}^{i+M-1}\}$: Sie $h \in C^M(\hat{\mathcal{P}})$ zu interpolierende Funktion. Es bezeichne $I_M^i : C^0(\hat{\mathcal{P}}) \rightarrow P_{M-1}(\hat{\mathcal{P}})$ Polynominterpolation zu $\{\mu^{i+m-1}\}_{m=1}^M$ für $M \geq 2$ und $i \in \{1, \dots, N\}$ s. d. $i + M \leq N + 1$.

Sei $L_M^{i;m} \in P_{M-1}(\hat{\mathcal{P}})$ Lagrange-Polynom zu den Stützstellen, d. h.

$$L_M^{i;m}(\hat{\mu}^{i+m'-1}) = \delta_{mm'} \quad \text{für } 1 \leq m, m' \leq M$$

Dann ist der Interpolant darstellbar als

$$(I_M^i h)(\hat{\mu}) = \sum_{m=1}^M L_M^{i;m}(\hat{\mu}) h(\hat{\mu}^{i+m-1})$$

Für den Interpolationsfehler gilt in $\hat{\mu} \in [\hat{\mu}^i, \mu^{i+M-1}]$

$$\begin{aligned} |h(\hat{\mu}) - (I_M^i h)(\hat{\mu})| &\leq \frac{\prod_{m=1}^M |\hat{\mu} - \hat{\mu}^{i+m-1}|}{\underbrace{M!}} \sup_{\hat{\mu}'} |h^{(M)}(\hat{\mu}')| \leq \frac{[(M-1)\delta_N]^M}{M!} \sup_{\hat{\mu}'} |h^{(M)}(\hat{\mu}')| \\ &\leq \frac{(\hat{\mu}^{i+M-1} - \hat{\mu}^i)^M}{M!} = \frac{[(M-1)\delta_N]^M}{M!} \end{aligned} \quad (3.18)$$

(endlich:)

Beweis. Satz 3.36

Idee: zeige Existenz eines $\hat{w}_N(\hat{\mu}) \in X_N$ s. d. (mit $\mu := \tau^{-1}(\hat{\mu})$)

$$\frac{\|\hat{u}(\hat{\mu}) - \hat{w}_N(\hat{\mu})\|_\mu}{\|\hat{u}(\hat{\mu})\|_\mu} \leq \mu_{max}^2 \cdot e^{\frac{-(N-1)}{N_0-1}} \quad \forall N \geq N_0 \quad (3.19)$$

Denn dann folgt Behauptung via $\|\hat{u}(\hat{\mu})\|_\mu = \|u(\mu)\|_\mu$ und

$$\|u(\mu) - u_N(\mu)\|_\mu = \inf_{v \in X_N} \|u(\mu) - v\|_\mu \leq \|u(\mu) - \hat{w}_N(\hat{\mu})\|_\mu = \|\hat{u}(\hat{\mu}) - \hat{w}_N(\hat{\mu})\|_\mu$$

Für Konstruktion eines $\hat{w}_N(\hat{\mu})$ reicht es, die Koeffizienten $\tilde{C}_n(\hat{\mu})$ zu definieren (siehe 3.41): Sei $\hat{\mu} \in \mathcal{P}$ gegeben und $M \in \{2, \dots, N\}$ wähle i s. d. $\hat{\mu} \in [\hat{\mu}^i, \hat{\mu}^{i+M-1}] =: J_M^i$, also $|J_M^i| = (M-1)d_N$

Definiere nun \tilde{C}_n durch Lagrange-Polynome zu $\{\hat{\mu}^{i+m-1}\}_{m=1}^M$:

$$\tilde{C}_n(\hat{\mu}) = \begin{cases} 0 & \text{falls } n < i \text{ oder } n \geq i + M \\ L_M^{i;n-i+1}(\hat{\mu}) & \text{falls } i \leq n \leq i + M - 1 \end{cases}$$

Dann ist zugehöriges $\tilde{g}_N(\hat{\mu}, \sigma)$ aus 3.41 Interpolierende im Sinne von

$$\tilde{g}_N(\hat{\mu}, \sigma) = (I_M^i g(\cdot, \sigma))(\hat{\mu})$$

denn

$$\tilde{g}_N(\hat{\mu}, \sigma) \stackrel{3.41}{=} \sum_{n=1}^N \tilde{C}_n(\hat{\mu}) g(\hat{\mu}^n, \sigma) = \sum_{n=i}^{i+n-1} L_M^{i;n-i+1}(\hat{\mu}) g(\hat{\mu}^n, \sigma) = (I_M^i g(\cdot, \sigma))(\hat{\mu})$$

also insbesondere $\tilde{g}_N(\hat{\mu}^n, \sigma) = g(\hat{\mu}^n, \sigma)$.

Betrachtet man die linke Seite von (3.19) für $\hat{w}_N(\hat{\mu})$: Mit 3.41 & 3.38 & 3.39 folgt

$$\begin{aligned} \frac{\|\hat{u}(\hat{\mu}) - \hat{w}_N(\hat{\mu})\|_\mu^2}{\|\hat{u}(\hat{\mu})\|_\mu^2} &\stackrel{3.39}{=} \frac{\sum_{i=1}^H \frac{f_i^2 (g(\hat{\mu}, \lambda_i) - \tilde{g}_N(\hat{\mu}, \lambda_i))^2}{g(\hat{\mu}, \lambda_i)}}{\sum_{i=1}^H \frac{f_i^2 g(\hat{\mu}, \lambda_i)^2}{g(\hat{\mu}, \lambda_i)}} \\ &= \frac{\sum_{i=1}^H f_i^2 g(\hat{\mu}, \lambda_i)^2 \frac{(g(\hat{\mu}, \lambda_i) - \tilde{g}_N(\hat{\mu}, \lambda_i))^2}{g(\hat{\mu}, \lambda_i)^2} \frac{1}{g(\hat{\mu}, \lambda_i)}}{\sum_{i=1}^H \frac{f_i^2 g(\hat{\mu}, \lambda_i)^2}{g(\hat{\mu}, \lambda_i)}} \\ &\leq \sup_{z, \sigma} \frac{(g(z, \sigma) - \tilde{g}_N(z, \sigma))^2}{g(z, \sigma)^2} \cdot \frac{\sum_{i=1}^H f_i^2 \frac{g(\hat{\mu}, \lambda_i)^2}{g(\hat{\mu}, \lambda_i)}}{\sum_{i=1}^H f_i^2 \frac{g(\hat{\mu}, \lambda_i)^2}{g(\hat{\mu}, \lambda_i)}} \\ &\leq \left(\sup_{z, \sigma} \frac{1}{g(z, \sigma)^2} \right) \left(\sup_{z, \sigma} (g(z, \sigma) - \tilde{g}_N(z, \sigma))^2 \right) \\ &\stackrel{3.40ii)}{\leq} \mu_{max}^2 \left(\sup_{z, \sigma} |g(z, \sigma) - \tilde{g}_N(z, \sigma)| \right)^2 \end{aligned} \tag{3.20}$$

Für Fehler rechts erhalte mittels Interpolationsfehlerabschätzung:

$$\begin{aligned} |g(z, \sigma) - \tilde{g}_N(z, \sigma)| &= |g(z, \sigma) - (I_M^i g(\cdot, \sigma))(z)| \\ &\stackrel{(3.18)}{\leq} \frac{((M-1)\delta_N)^M}{M!} \sup_{\hat{\mu}'} \underbrace{\left| \frac{\partial^M}{\partial \hat{\mu}^M} g(\hat{\mu}', \sigma) \right|}_{\leq \bar{C} C^M M! \text{ wegen 3.40 ii)}} \\ &= \frac{((M-1)\delta_N)^M}{M!} \cdot \bar{C} C^M M! \\ &= (C(M-1)\delta_N)^M \cdot \bar{C} \end{aligned} \tag{3.21}$$

Bisher: M beliebig. Finde nun $M_{opt} \in \{2, \dots, N\}$, welches den Fehler “klein” macht. Suche zunächst ein reelles $\bar{M}_{opt} \in [2, N] \subset \mathbb{R}$. Hierzu setze

$$\bar{M}_{opt} := 1 + \frac{1}{C e \delta_N}$$

Wir sehen mit Abkürzung $\lambda := \ln \mu_{max} - \ln \mu_{min} = 2 \ln \mu_{max}$

$$\begin{aligned} \frac{1}{Ce\delta_N} \geq 1 &\iff 1 \geq Ce \frac{\ln \mu_{max} - \ln \mu_{min}}{N-1} \iff N-1 \geq C \cdot e \cdot \lambda \\ &\iff N \geq Ce\lambda + 1 \end{aligned}$$

Also ist mit Forderung $N_0 \geq C \cdot e \cdot \lambda + 1$ ist $\bar{M}_{opt} \geq 2$. Weiter:

$$\begin{aligned} 1 + \frac{1}{Ce\delta_N} &\iff \frac{1}{Ce\delta_N} \iff 1 \leq (N-1)(Ce\delta_N) \\ &\iff 1 \leq (N-1)C \cdot e \frac{\lambda}{N-1} \iff 1 \leq Ce\lambda \\ &\stackrel{3.40}{\iff} 1 \leq 2\mu_{max}^2 \cdot e \cdot 2 \ln \mu_{max} \end{aligned}$$

Also ist für μ_{max} genügend groß $\bar{M}_{opt} \leq N$.

Insgesamt nun also $\bar{M}_{opt} \in [2, N]$.

Wegen $C(\bar{M}_{opt} - 1)\delta_N = C \frac{1}{Ce\delta_N} \cdot \delta_N = \frac{1}{e}$ folgt

$$\left(C(\bar{M}_{opt} - 1)\delta_N \right)^{\bar{M}_{opt}-1} = \left(\frac{1}{e} \right)^{\frac{1}{Ce\delta_N}} = e^{-\frac{1}{Ce\delta_N}} = e^{-\frac{N-1}{Ce\lambda}} \leq e^{-\frac{N-1}{N_0-1}}$$

falls $Ce\lambda \leq N_0 - 1$, d. h. $N_0 \geq Ce\lambda + 1$ (identische Forderung an N_0 wie zuvor). Setze nun $M_{opt} := \lfloor \bar{M}_{opt} \rfloor$ größte ganze Zahl kleiner/gleich \bar{M}_{opt}

$$\Rightarrow M_{opt} \in \{2, \dots, N\}$$

$$\text{wg. } M_{opt} \leq \bar{M}_{opt} \Rightarrow C(M_{opt} - 1)\delta_N \leq C(\bar{M}_{opt} - 1)\delta_N \left(= \frac{1}{e} < 1 \right)$$

$$\text{und } M_{opt} > \bar{M}_{opt} - 1$$

folgt

$$(C(M_{opt} - 1)\delta_N)^{M_{opt}} \leq (C(\bar{M}_{opt} - 1)\delta_N)^{\bar{M}_{opt}} \leq e^{-\frac{N-1}{N_0-1}} \quad (3.22)$$

Damit insgesamt

$$\begin{aligned} \frac{\|\hat{u}(\hat{\mu}) - \hat{w}_N(\hat{\mu})\|_\mu}{\|\hat{u}(\hat{\mu})\|_\mu} &\stackrel{(3.20)}{\leq} \mu_{max} \sup_{z, \sigma} |g(z, \sigma) - \tilde{g}_N(z, \sigma)| \\ &\stackrel{(3.21)}{\leq} \mu_{max} \underbrace{\bar{C}}_{=\mu_{max}} \cdot (C(M_{opt} - 1)\delta_N)^{M_{opt}} \stackrel{(3.22)}{\leq} \mu_{max}^2 e^{-\frac{N-1}{N_0-1}} \end{aligned}$$

also (3.19) und damit Satz 3.36 gezeigt. □

Definition 3.42 (Gram-Schmidt)

Seien $\{u_i\}_{i=1}^n \in X$ lin. unabh. Dann ist *Gram-Schmidt Basis* $\Phi_{GR} := \{\varphi_1, \dots, \varphi_n\}$ definiert durch

$$\bar{\varphi}_m := u_m - \sum_{i=1}^{m-1} \langle u_m, \varphi_i \rangle \varphi_i \quad , \quad \varphi_m := \frac{\bar{\varphi}_m}{\|\bar{\varphi}_m\|} \quad , \quad m = 1, \dots, n$$

und X_{GR} der zugehörige *Gram-Schmidt RB-Raum*

Lemma 3.43 (Eigenschaften von Φ_{GR})

- i) Φ_{GR} ist ONB
- ii) $\text{span}\{u_i\}_{i=1}^n = X_{GR}$

Beweis. i) Normiertheit klar nach Definition

Orthogonalität per Induktion:

Sei $\langle \varphi_i, \varphi_j \rangle = 0 \quad \forall \quad j < i$

Dann gilt für $j < i + 1$:

$$\begin{aligned} \langle \bar{\varphi}_{i+1}, \varphi_j \rangle &= \langle u_{i+1}, \varphi_j \rangle - \sum_{k=1}^{(i+1)-1} \langle u_{i+1}, \varphi_k \rangle \underbrace{\langle \varphi_k, \varphi_j \rangle}_{\delta_{kj} \text{ sowohl für } j < i \text{ als auch } j=i} \\ &= \langle u_{i+1}, \varphi_j \rangle - \langle u_{i+1}, \varphi_j \rangle = 0 \end{aligned}$$

also auch $\langle \varphi_{i+1}, \varphi_j \rangle = \langle \frac{\bar{\varphi}_{i+1}}{\|\bar{\varphi}_{i+1}\|}, \varphi_j \rangle = 0$

- ii) “ \supseteq ” klar nach Konstruktion
- “ $=$ ” folgt durch Dimensionsbetrachtung:

$$\dim \text{span}\{\varphi_i\}_{i=1}^n = n = \dim \text{span}\{u_i\}_{i=1}^n$$

□

Bemerkung.

- Algorithmus liefert also ONB, garantiert Stabilität des RB-Verfahren für symmetrisches $a(\cdot, \cdot)$ gemäß 3.7
- Es existiert nur triviale Approximationsaussage, z. B. wegen ii):

$$\max_{j=1, \dots, m} \inf_{v \in X_{GR}} \|u_j - v\| = 0$$

Für Teilbasis $\Phi_{GR,m} := \{\varphi_1, \dots, \varphi_m\}$, $m < n$ werden $\{u_i\}_{i=1}^m$ exakt approximiert über $\{u_i\}_{i=m+1}^n$ weiß man nichts.

- Basis hängt von Reihenfolge der $\{u_i\}_{i=1}^n$ ab, macht also nur Sinn, wenn diese eine natürliche Reihenfolge haben.

- Gram Schmidt Orthonormierung folgt häufig als “Postprocessing” für anderweitig erzeugte Basis, z. B. Lagrange-, Greedy-Basis, etc.

Satz 3.44 (Berechnung von Φ_{GR} über Gram-Matrix)

Seien $\{u_i\}_{i=1}^m \subset X$ lin. unabh., $K = (\langle u_i, u_j \rangle)_{i,j=1}^n$ mit Cholesky-Zerlegung $K = LL^T$, d. h. L untere Δ -Matrix mit positiver Diagonalen. Definiere $A = (a_{ij})_{i,j=1}^n := (L^T)^{-1}$. Dann ist die Gram-Schmidt ONB Φ_{GR} äquivalent berechenbar durch

$$\varphi_j = \sum_{i=1}^j a_{ij} u_i \quad \text{für} \quad 1 \leq j \leq n$$

Beweis. Übung. □

Proper Orthogonal Decomposition (POD)

Definition 3.45 (Korrelationsoperator)

Sei $\{u_i\}_{i=1}^n \subset X$. Dann definieren wir den *empirischen Korrelationsoperator* $R \in L(X, X)$ durch

$$Ru := \frac{1}{n} \sum_{i=1}^n \langle u_i, u \rangle u_i \quad \forall u \in X$$

Bemerkung.

- Linearität von R ist klar, Beschränktheit folgt wegen

$$\|Ru\| \leq \frac{1}{n} \sum \|u_i\|^2 \|u\| \Rightarrow \|R\| = \sup_{u \neq 0} \frac{\|Ru\|}{\|u\|} \leq \frac{1}{n} \sum \|u_i\|^2 < \infty$$

also $R \in L(X, X)$

- Wir nennen ein $A \in L(X, X)$ *kompakt* falls abgeschlossenes Bild der offenen Einheitskugel, d. h. $\overline{A(B_1(0))}$, kompakt ist
- Wir nennen $A \in L(X, X)$ *selbstadjungiert* (genauer Hilbertraum-selbstadjungiert), falls $\langle Au, v \rangle = \langle u, Av \rangle \quad \forall u, v \in X$

Satz 3.46 (Spektralsatz)

Sie $A \in L(X, X)$ kompakt & selbstadjungiert, dann existiert endliche oder abzählbar unendliche orthonormiertes System von Eigenvektoren $\{\varphi_i\}_{i \in I}$, $I \subseteq \mathbb{N}$ zu Eigenwerten $\{\lambda_i\}_{i \in I} \subset \mathbb{R} \setminus \{0\}$ mit

$$Au = \sum_{i \in I} \lambda_i \langle u, \varphi_i \rangle \varphi_i \quad \forall u \in X$$

Falls I unendlich, so $\lim_{i \rightarrow \infty} \lambda_i = 0$.

Beweis. z. B. Alt: “lineare Funktionalanalysis” Satz 12.12 □

Satz 3.47 (POD-Basis)

Zu $\{u_i\}_{i=1}^n$ mit R aus 3.45 existiert orthonormierte Menge $\{\varphi_i\}_{i=1}^{n'}$ von $n' \leq n$ Eigenvektoren zu reellen Eigenwerten $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_{n'} > 0$ mit

$$Ru = \sum_{i=1}^{n'} \lambda_i \langle \varphi_i, u \rangle \varphi_i \quad (3.23)$$

Für $m = 1, \dots, n'$ definieren $\Phi_{POD} := \Phi_{POD,m} := \{\varphi_i\}_{i=1}^m$ als *POD-Basis* und $X_{POD} := X_{POD,m} := \text{span } \Phi_{POD,m}$ als POD-Raum.

Beweis. R hat endlich dimensionales Bild, also $\overline{R(B_1(0))}$ abgeschlossen, beschränkt im endlich dimensionalen Raum, also kompakt. R ist selbstadjungiert, denn $\langle Ru, v \rangle = \frac{1}{n} \sum_{i=1}^n \langle u_u, u \rangle \langle u, v \rangle = \langle u, Rv \rangle$. Also existiert nach Spektralsatz 3.46 entsprechend endliches ONS, das (3.23) erfüllt. Dies kann insbesondere nicht unendlich sein, wegen endlichem Bild. \square

Bemerkung.

- Die Projektion $X \rightarrow X_{POD}$ wird in der statistischen Datenanalyse auch Hotelling-Transformation, Principal Component Analysis (PCA) oder Karhunen-Loève-Transformation genannt.
- Bezeichnung POD, als “proper”, ist Anlehnung an das französische “valeur propre” für Eigenwert.
- Wir nennen Basisvektoren von Φ_{POD} auch POD-Moden.

Illustration

- $\{\varphi_i\}_{i=1}^{n'}$ ist ONB für $\text{span}\{u_i\}_{i=1}^n$ aber nicht eindeutig (VZ oder vertauschen bei mehrfachen Eigenwerten)
- φ_1 ist Richtung höchster Varianz von $\{u_i\}_{i=1}^n$
 φ_2 ist Richtung höchster Varianz von $\{P_{x_{POD,1}}^\perp u_i\}_{i=1}^n$
- Koordinaten der Daten in der POD-Basis sind unkorreliert \rightarrow Übung.
- $\{\varphi_i\}, \{\sqrt{\lambda_i}\}$ sind die Hauptachsen bzw. Achsenabschnitte des Ellipsoids $\{\langle u, R^{-1}u \rangle = 1\}$
- Falls $X = \mathbb{R}^H$ und $\{u_i\}_{i=1}^n$ Realisierungen von n unabhängigen, identisch normalverteilten Zufallsvariablen mit Verteilung $\mathcal{N}(\mu, \Sigma) := C \cdot \exp(-(x - \mu)^T \Sigma (x - \mu))$ mit Mittelwert $\mu = 0$, so ist $R \in \mathbb{R}^{H \times H}$ guter Schätzer für Σ , insbesondere $R \rightarrow \Sigma$ konvergiert für $n \rightarrow \infty$ in geeignetem Sinne.




Abbildung 7: Ellipsoide aus Kovarianzoperator
(aus B. Haasdonk, Reduzierte-Basis-Methoden, Skript zur Vorlesung SS 2011, Universität Stuttgart, IANS-Report 4/11, 2011.)

Satz 3.48 (Berechnung von Φ_{POD} über Gram-Matrix)

Sei $\{u_i\}_{i=1}^n \subset X$ und $K = (\langle u_i, u_j \rangle)_{i,j=1}^n$. Dann sind äquivalent:

i) $\varphi \in X$ ist Eigenvektor von R zu Eigenwert $\lambda > 0$ mit Norm 1 und einer Darstellung

$$\varphi = \sum a_i u_i \quad \text{mit o. B. d. A. } a \in \ker(K)^\perp$$

ii) $a = (a_i)_{i=1}^n \in \mathbb{R}^n$ ist Eigenvektor von $\frac{1}{n}K$ zu $\lambda > 0$ mit Norm $\frac{1}{\sqrt{n\lambda}}$

Beweis. ii) \Rightarrow i)

Sei a Eigenvektor von $\frac{1}{n}K$ zu Eigenwert λ mit $\|a\| = \frac{1}{\sqrt{n\lambda}}$ also

$$\lambda a = \frac{1}{n} K a$$

Multiplikation der i -ten Komponenten mit u_i und Summieren ergibt

$$\sum_{i=1}^n u_i \lambda a_i = \sum_{i=1}^n u_i \frac{1}{n} \left(\underbrace{\sum_{j=1}^n \langle u_i, u_j \rangle a_j}_{(Ka)_i} \right)$$

Mit $\varphi := \sum u_i a_i$ gilt also

$$\lambda \varphi = \frac{1}{n} \sum_{i=1}^n u_i \langle u_i, \varphi \rangle = R \varphi$$

Also φ Eigenvektor von R zu Eigenwert λ . Für Norm folgt

$$\|\varphi\|^2 = \langle \sum a_i u_i, \sum a_j u_j \rangle = a^T \underbrace{K a}_{n\lambda a} = n\lambda \cdot \|a\|^2 = 1$$

K ist symmetrisch, also existiert vollständiges ONS von Eigenvektoren. $\ker(K)$ wird aufgespannt von EV zu EW 0, also $a \perp \ker(K)$, a EV zu $\lambda > 0$.

i) \Rightarrow ii):

Sie φ EV von R zu EW $\lambda > 0$ und $\|\varphi\| = 1$. Sei $\bar{a} \in \mathbb{R}^n$ mit $\varphi = \sum \bar{a}_i u_i$ (existiert weil $\varphi \in \text{Bild}(R) = \text{span}\{u_i\}_{i=1}^n$). Verschiebungen von \bar{a} um $a^0 \in \ker(K)$ erhalten φ :

$$\begin{aligned}\varphi' &:= \sum (\bar{a}_i + a_i^0) u_i \Rightarrow \langle \varphi', u_k \rangle = \left\langle \sum_{i=1}^n \bar{a}_i u_i, u_k \right\rangle + \left\langle \sum_i a_i^0 u_i, u_k \right\rangle \\ &= \langle \varphi, u_k \rangle + \underbrace{\sum_{i=1}^n a_i^0 \langle u_i, u_k \rangle}_{K a^0 = 0} \quad , \quad k = 1, \dots, n\end{aligned}$$

Also $\varphi' = \varphi$.

Wähle speziell $a := \bar{a} - P\bar{a}$, P orthogonale Projektion auf $\ker(K)$.

$$\Rightarrow a \in \ker(K)^\perp, \quad P\bar{a} \in \ker(K) \quad \Rightarrow \quad \varphi = \sum \bar{a}_i u_i = \sum a_i u_i$$

i) \Rightarrow ii) o.B.d.A. $a \in \ker(K)^\perp$

Da $\varphi \in V$ zu $\lambda > 0$ gilt:

$$\underbrace{\frac{1}{n} \sum_{i=1}^n \langle u_i, \sum_{j=1}^n a_j u_j \rangle u_i}_{R\varphi} = \lambda \varphi = \lambda \sum_j a_j u_j$$

Testen mit u_k liefert

$$\underbrace{\frac{1}{n} \sum_j \langle u_i, u_j \rangle \langle u_i, u_k \rangle a_j}_{(K^2 a)_k} = \lambda \underbrace{\sum_j a_j \langle u_j, u_k \rangle}_{(Ka)_k}$$

Also $\frac{1}{n} K^2 a = \lambda K a$ also $K a$ EV von $\frac{1}{n} K$ zu EW λ . Dann ist schon a EV, denn $a \in \ker(K)^\perp$:

$$(*) \quad K a \left(\frac{1}{n} K - \lambda \right) a = 0$$

$a \in \ker(K)^\perp$, $K a \in \ker(K)^\perp$ wegen Symmetrie $\langle K a, v \rangle = \langle a, K v \rangle = 0 \quad \forall v \in \ker(K)$

$\Rightarrow (\frac{1}{n} K - \lambda) a \in \ker(K)^\perp$

aber auch wg. (*) $(\frac{1}{n} K - \lambda) a \in \ker(K)$

$\Rightarrow (\frac{1}{n} K - \lambda) a = 0$ also a EV von $\frac{1}{n} K$ zu λ .

Wie im ersten Teil gilt

$$1 = \|\varphi\|^2 = \sum a_i a_j \langle u_i, u_j \rangle = a^T K a = a^T \cdot n \lambda a = n \lambda a \|a\|^2$$

$$\Rightarrow \|a\| = \frac{1}{\sqrt{n \cdot \lambda}}$$

□

Bemerkung. Falls X endlichdimensional $\dim(X) = H$, kann daher POD entweder als teures EWP für R in X (Komplexität $\mathcal{O}(H^3)$) oder, meist günstiger, als EWP für K (Komplexität $\mathcal{O}(n^3)$) ermittelt werden.

Bezeichnung für letzteres ist auch “method of snapshots” (Sirovich, 1987) oder Kernel-PCA (Scholkopf & Smola, 2002). POD kann auch über Singulärwertzerlegung der Koeffizientenmatrix berechnet werden:

Satz 3.49 (Berechnung für $X = \mathbb{R}^H$ via SVD)

Sei $X = \mathbb{R}^H$ mit $\langle \cdot, \cdot \rangle = \langle \cdot, \cdot \rangle_{\mathbb{R}^H}$. $U = [u_1, \dots, u_n] \in \mathbb{R}^{H \times n}$ Snapshot-Matrix mit Rang $U = n'$ und

$$U = \Phi S V^T$$

eine verkürzte SVD, d.h. $\Phi \in \mathbb{R}^{H \times n'}$, $V \in \mathbb{R}^{n \times n'}$ orthonormale Spalten und $S = \text{diag}(\sigma_1, \dots, \sigma_{n'}) \in \mathbb{R}^{n' \times n'}$ (σ_i : Singulärwerte) mit $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_{n'} \geq 0$.

Dann ist $\Phi_{POD, n'} = \Phi$.

Beweis. Sei $\Phi = (\bar{\varphi}_1, \dots, \bar{\varphi}_n)$. Nach Definition gilt $Ru = \frac{1}{n} U U^T U \quad \forall u \in \mathbb{R}^H$. Damit ist $\bar{\varphi}_i$ EV von R zu i -ten Eigenwert $\frac{1}{n} \sigma_i^2$:

$$\begin{aligned} R \bar{\varphi}_i &= \frac{1}{n} U U^T \bar{\varphi}_i = \frac{1}{n} \Phi \underbrace{S V^T V}_I S \underbrace{\Phi^T \bar{\varphi}_i}_{e_i \in \mathbb{R}^{n'}} \\ &= \frac{1}{n} \Phi \underbrace{S^2 e_i}_{\sigma_i^2 e_i} = \frac{1}{n} \sigma_i^2 \bar{\varphi}_i \end{aligned}$$

Die EW $\frac{1}{n} \sigma_i^2$ sind monoton fallend, also identisch sortiert wie EW von R , das heißt $\lambda_i = \frac{1}{n} \sigma_i^2$ und $\varphi_i = \bar{\varphi}_i$. \square

Bemerkung.

- obiges ist sehr eingänglich (“1-Zeilenbeweis”), aber algorithmisch nicht unbedingt besser, weil SVD auch durch EWP definiert (Numerik I)
- Verallgemeinerung für allg. HR $X \rightarrow$ Übung (Blatt 5)

Satz 3.50 (Approximationsfehler für $X_{POD, m}$)

Sei $\{u_i\}_{i=1}^n \subset X$ und für $Y \subset X$ Unterraum ist mittlerer quadratischer Fehler $J(Y) := \frac{1}{n} \sum_{i=1}^n \|u_i - P_Y u_i\|^2$. Dann gilt für den POD-Raum

$$J(X_{POD, m}) = \sum_{i=m+1}^{n'} \lambda_i \quad \text{für } m = 1, \dots, n'$$

mit λ_i EW von R .

Beweis. Sei $\Psi = \{\Psi_1, \dots, \Psi_m\}$ ONB für Y . Dann folgt

$$\begin{aligned}
J(Y) &= \frac{1}{n} \sum_{i=1}^n \|u_i - P_Y u_i\|^2 = \frac{1}{n} \sum_{i=1}^n \left\| u_i - \sum_{j=1}^m \langle \Psi_j, u_i \rangle \Psi_j \right\|^2 \\
&= \frac{1}{n} \sum_{i=1}^n \|u_i\|^2 - \frac{2}{n} \sum_{i=1}^n \sum_{j=1}^m \langle u_i, \Psi_j \rangle^2 + \frac{1}{n} \sum_{i=1}^n \sum_{j,k} \langle \Psi_j, u_i \rangle \langle u_i, \Psi_k \rangle \underbrace{\langle \Psi_j, \Psi_k \rangle}_{=\sigma_{jk}} \\
&= \frac{1}{n} \sum_{i=1}^n \|u_i\|^2 - \frac{1}{n} \sum_{i=1}^n \sum_{j=1}^m \langle u_i, \Psi_j \rangle^2
\end{aligned}$$

Wegen $u_i \in \text{Bild}(R) = X_{POD, n'}$ ist $u_i = \sum_{j=1}^{n'} \langle \varphi_j, u_i \rangle \varphi_j$

$$\|u_i\|^2 = \sum_{j,k=1}^{n'} \langle \varphi_j, u_i \rangle \langle \varphi_k, u_i \rangle \underbrace{\langle \varphi_j, \varphi_k \rangle}_{=\sigma_{jk}} = \sum_{j=1}^{n'} \langle \varphi_j, u_i \rangle^2$$

also mittlerer quadratischer Projektionsfehler:

$$\begin{aligned}
J(X_{POD, m}) &= \frac{1}{n} \sum_{i=1}^n \sum_{j=1}^{n'} \langle \varphi_j, u_i \rangle^2 - \frac{1}{n} \sum_{i=1}^n \sum_{j=1}^m \langle u_i, \varphi_j \rangle^2 \\
&= \left(\frac{1}{n} \sum_{i=1}^n \sum_{j=m+1}^{n'} \langle \varphi_j, u_i \rangle^2 \right) = \frac{1}{n} \sum_{i=1}^n \sum_{j=m+1}^{n'} \langle \varphi_j, u_i \rangle \langle \varphi_j, u_i \rangle \\
&= \sum_{j=m+1}^{n'} \langle \varphi_j, \frac{1}{n} \sum_{i=1}^n \langle \varphi_j, u_i \rangle u_i \rangle \\
&= \sum_{j=m+1}^{n'} \langle \varphi_j, \underbrace{R \varphi_j}_{=\lambda_j \varphi_j} \rangle = \sum_{j=m+1}^{n'} \lambda_j
\end{aligned}$$

□

Satz 3.51 (Bestapproximation durch $X_{POD, m}$)

Unter allen Räumen der Dimension m ist $X_{POD, m}$ bzgl. J optimal

$$j(X_{POD, m}) = \inf_{\substack{Y \subseteq X \\ \dim Y = m}} J(Y)$$

Beweis. Übung.

□

Bemerkung (Zusammenfassung).

- POD liefert also orthonormale Basis, garantiert Stabilität des RB-Verfahrens (bei symmetrischem $a(\cdot, \cdot)$)

- Es existieren Approximationsaussagen bzgl. des mittleren quadratischen Projektionsfehlers, sogar Optimalität nachweisbar. Die POD Teilbasen ermöglichen Approximation aller Snapshots mit Fehlerkontrolle der abgeschnittenen Eigenwerte.
- Die POD-Basis hängt nicht von Reihenfolge der Snapshots ab.
- Die POD-Basen sind hierarchisch:

$$\Phi_{POD,m} \subseteq \Phi_{POD,m'} \quad \text{für } m \leq m'$$

- Die POD kann auch zur Erweiterung einer bestehenden ONB Φ verwendet werden, indem $\{\tilde{u}_i\}_{i=1}^n$, $\tilde{u}_i = u_i - P_{\text{span}(\Phi)}u_i$ und eine POD Basis $\tilde{\Phi}_{POD}$ hierfür berechnet wird. Dann ist $\Phi \cup \tilde{\Phi}_{POD}$ eine erweiterte/neue ONB.
- Man kann POD auch als inkrementelles Verfahren mit 1D-Minimierung von $J(Y)$ verstehen.

Sei $\{u_i\}_{i=1}^n \subset X$. Dann definiere

$$\bar{\varphi}_1 := \text{POD}_1(\{u_i\}_{i=1}^n) := \operatorname{arginf}_{\substack{\varphi \in X \\ \|\varphi\|=1}} \frac{1}{n} \sum_{i=1}^n \|u_i - \langle u_i, \varphi \rangle \varphi\|^2$$

$$\bar{X}_1 := \text{span}(\bar{\varphi}_1)$$

und für $i = 2, \dots, n'$

$$\bar{\varphi}_i := \text{POD}_1(\{u_i - P_{\bar{X}_{i-1}}u_i\}),$$

$$\bar{X}_i := \text{span}(\bar{\varphi}_1, \dots, \bar{\varphi}_i)$$

Dann ist $(\bar{\varphi}_1, \dots, \bar{\varphi}_m)$ POD-Basis (aus m Moden/Basisvektoren) (bis auf Rotation, Vorzeichen).

Greedy-Verfahren

Definition 3.52 (Greedy-Verfahren)

Sei $S_{\text{train}} \subset \mathcal{P}$ "Trainingsmenge" von Parametern, $\Delta(Y, \mu) \in \mathbb{R}^+$ für Teilräume $Y \subset X$ und Parameter $\mu \in \mathcal{P}$ ein "Fehlerindikator" und $\epsilon_{\text{tol}} > 0$ eine Fehlertoleranz. Die Greedy-Basen $\Phi_{GRE,m}$, Greedy-Raum $X_{GRE,m}$ und Sample-Menge S_m für $m = 0, \dots, N$ sind iterativ definiert durch

$$S_0 = \emptyset, \quad X_{GRE,0} = \{0\}, \quad \Phi_{GRE,0} = \emptyset, \quad m := 0$$

Solange $\epsilon_m := \max_{\mu \in S_{train}} \Delta(X_{GRE,m}, \mu) > \epsilon_{tol}$

$$\mu^{(m+1)} := \operatorname{maxarg}_{\mu \in S_{train}} \Delta(X_{GRE,m}, \mu)$$

$$S_{m+1} := S_m \cup \{\mu^{(m+1)}\}$$

$$\varphi_{m+1} := u(\mu^{(m+1)}) \text{ Lösung von } (P(\mu^{(m+1)}))$$

$$\Phi_{GRE,m+1} := \Phi_{GRE,m} \cup \{\varphi_{m+1}\}$$

$$X_{GRE,m+1} := X_{GRE,m} + \operatorname{span}(\varphi_{m+1})$$

$$m \leftarrow m + 1$$

setze schließlich $N := m$

Bemerkung.

- Erste Verwendung von Greedy-Verfahren für RB: Veroy, Prud'homme, Rovas, Patera 2003, seitdem "Standard"
- $\Phi_{GRE,m}$ ist Lagrange-RB zur Sample-Menge S_m , i. a. nicht orthonormal. Kann für numerische Stabilität mit Gram-Schmidt orthonormalisiert werden.
- Basen sind hierarchisch: $\Phi_{GRE,m} \subset \Phi_{GRE,m'}, m \leq m'$
- In Literatur wird Suche nach $\mu^{(1)}$ häufig umgangen, indem dieses beliebig aus S_{train} gewählt wird.
- S_{train} wird häufig als strukturierte oder zufällige Menge aus \mathcal{P} mit *endlich* vielen Samples gewählt.
- Falls S_{train} zu klein, kann das RB-Modell overfitting aufweisen, d. h.

$$\sup_{\mu \in \mathcal{P}} \|u(\mu) - u_N(\mu)\| >> \sup_{\mu \in S_{train}} \|u(\mu) - u_N(\mu)\|$$

- Greedy-Verfahren ist also akkumulatives Verfahren, welches iterativ den "schlechtest"-aufgelösten Parameter $\mu^{(m+1)}$ wählt, $u(\mu^{(m+1)})$ berechnet, und als neuen Basisvektor hinzufügt. Insofern kann dies als approximative Lösung des Optimierungsproblems

$$\min_{\substack{Y \subset X \\ \dim Y = N}} \max_{\mu \in \mathcal{P}} \Delta(Y, \mu)$$

interpretiert werden: Statt maximieren über $\mathcal{P} \rightsquigarrow$ maximieren über S_{train} , statt minimieren über $X \subset X \rightsquigarrow$ iterative Sequenz von Räumen $Y = X_{GRE,m}$.

Lemma 3.53 (Fehlerindikatoren, Terminieren des Verfahrens)

- i) Falls $|S_{train}| = n < \infty$ und für alle $\mu \in \mathcal{P}$ und $Y \subset X$ gilt

$$u(\mu) \in Y \Rightarrow \Delta(Y, \mu) = 0$$

so terminiert das Greedy-Verfahren mit $N \leq n$ und

$$\max_{\mu \in S_{train}} \Delta(X_{GRE,n}, \mu) \leq \epsilon_{tol}$$

ii) Dies erfüllen z. B.

$$\Delta(Y, \mu) := \|u(\mu) - u_N(\mu)\|$$

$$\Delta(Y, \mu) := \|u(\mu) - P_y u(\mu)\|$$

$$\Delta(Y, \mu) := \Delta_N^{en}(\mu)$$

oder andere Fehlerschätzer, wobei $X_N = Y$ gesetzt wird.

Beweis. Übung. □

Korollar 3.54 (Fehlerraussage)

Für $\Delta(Y, \mu) := \|u(\mu) - u_N(\mu)\|$ oder $\Delta(Y, \mu) := \Delta_{N'}$ gilt für $N' = 1, \dots, N$

$$\max_{\mu \in S_{train}} \|u(\mu) - u_{N'}(\mu)\| \leq \epsilon_{N'}$$

Beweis. Klar nach Konstruktion. □

Bemerkung (Wahl der Fehlerindikatoren).

- Greedy-Verfahren hervorragendes Einsatzfeld für Fehlerschätzer, denn $\Delta_N(\mu)$ kann sehr schnell für alle $\mu \in S_{train}$ ausgerechnet werden, ohne dass alle $u(\mu)$, $\mu \in S_{train}$ berechnet werden müssen (im Gegensatz zu POD). Dadurch können sehr große Mengen S_{train} behandelt werden. Dies erhöht die Erwartung, dass $\Phi_{GRE,N}$ auch für neue Parameter $\mu \in \mathcal{P} \setminus S_{train}$ eine gute Approximation liefert.

- Wahl: $\Delta(Y, \mu) := \|u(\mu) - P_y u(\mu)\|$, orthogonaler Projektionsfehler

Motivation: Falls dies klein, so ist mit Céa auch RB-Fehler klein

Nachteile: Teuer auszuwerten, hochdimensionale Operation erfordert alle Snapshots $u(\mu)$, $\mu \in S_{train}$ müssen vorliegen, Größe von S_{train} hiermit eingeschränkt.

Vorteil: Terminieren ist garantiert. Approximationsraum ist entkoppelt von RB-Approximation, d. h. Verfahren kann angewandt werden ohne Vorliegen des RB-Verfahrens und ohne Fehlerschätzer.

- Wahl: $\Delta(Y, \mu) := \|u(\mu) - u_N(\mu)\|$, RB-Fehler

Motivation: Dies ist die ultimative Größe, welche kontrolliert werden muss, z. B. (3.7).

Nachteile: Wie bei Projektionsfehler: teuer, alle Snapshots $\mu \in S_{train}$ vorberechnen, S_{train} Größe eingeschränkt.

Vorteile: Terminieren ist garantiert, Verfahren kann mit RB-Verfahren angewandt werden, für welche keine FS vorliegen.

- Wahl: $\Delta(Y, \mu) = \Delta_N(\mu)$ [oder Energie-/rel. Fehlerschätzer]
Nachteil: Falls Fehlerschätzer den Fehler stark überschätzt, kann der RB-Raum evtl. größer als nötig sein.
Vorteile: schnell auswertbar, unabhängig von H denn Offline-Online. Es müssen nur N Snapshots berechnet werden, $|S_{train}|$ kann sehr groß gewählt werden, Terminieren kann garantiert werden.
- Ziel-orientierte Indikatoren: Falls $\Delta(Y, \mu)$ als Ausgabefehler $|s(\mu) - s_N(\mu)|$ oder -Schranke $\Delta_{N,s}$ gewählt wird, nennt man das Verfahren “goal-oriented”. Die Basis wird potentiell sehr klein und kann Ausgabe gut approximieren. Die Feldvariable u wird jedoch nicht notwendigerweise gut approximiert.
- Falls $\Delta(Y, \mu)$ als Feldvariablen-Fehler $\|u(\mu) - u_N(\mu)\|$, PProjektionsfehler oder -schätzer gewählt wird, ist Verfahren nicht goal-oriented, die Basis wird größer sein, aber sowohl u als auch v , als auch beliebig andere Funktionale \tilde{s} gut approximiert.

Bemerkung (Reihenfolge).

- Greedy-Basis hängt meistens nicht von Reihenfolge der Parameter S_{train} ab. Nur falls zufällig das Maximum von $\Delta(Y, \mu)$ mehrdeutig ist \rightsquigarrow Praktische Lösung: Wähle ersten Parameter, der maximales $\Delta(Y, \mu)$ erzeugt.

Bemerkung (Bestimmung der Approximationsgüte/Overfitting). In Terminologie der Statistik/Maschinellen Lernens ist S_{train} eine *Trainingsmenge* und ϵ_N aus Greedy-Verfahren der sogenannten *Trainingsfehler*. S_{train} muss \mathcal{P} gut repräsentieren, sollte möglichst groß gewählt werden. Falls S_{train} zu klein, oder unrepräsentativ für \mathcal{P} kann Overfitting auftreten.

Somit ist kleiner Trainingsfehler nicht hinreichend für gutes Modell. Modelle sollen daher nicht alleine anhand von Trainings-, sondern anhand unabhängiger Testmengen:

$$\epsilon_{test} = \max_{\mu \in S_{train}} \Delta(X_N, \mu) \quad , \text{ meistens zufällige Parametermenge}$$

Bemerkung (Monotonie).

- Im Allgemeinen gilt nicht $\Delta(X_N, \mu) \geq \Delta(X_{n+1}, \mu)$
- Es kann daher vorkommen, dass $(\epsilon_n)_{n=1}^N$ nichtmonoton ist.
- Falls Beziehung zu Bestapproximation gilt, d. h. für ein $C > 0$ unabhängig von n gilt:

$$\Delta(X_n, \mu) \leq C \cdot \inf_{v \in X_n} \|u(\mu) - v\|$$

kann zumindest eine Beschränkung oder asymptotischer Abfall erwartet werden.

- In bestimmten Fällen kann Monotonie bewiesen werden:

Satz 3.55 (Monotonie von (ϵ_n))

Das Greedy-Verfahren erzeugt monoton fallende Sequenzen $(\epsilon_n)_{n \geq 1}$ falls:

- i) $\Delta(Y, \mu) := \|u(\mu) - P_{X_n} u(\mu)\|$ oder
- ii) (P) ist compliant, d. h. $l = f$ und a symmetrisch und $\Delta(Y, \mu) = \|u(\mu) - u_N(\mu)\|_\mu$

Beweis. i) klar

- ii) folgt aus 3.11

□

Bemerkung (Konvergenz des Greedy-Verfahrens).

- Einige Jahre lang war Greedy-Verfahren ein in der Praxis gut funktionierendes Verfahren, jedoch ohne theoretische Erklärung wann/warum es funktioniert.
- Notwendiges Kriterium für Erfolg des Greedy-Verfahren: Kolmogorov n -Weite von \mathcal{M} muss (schnell) abfallen. Sei $\Delta(Y, \mu)$ so gewählt, dass $\Delta(Y, \mu) \geq \|u(\mu) - P_Y u(\mu)\|$

$$\Rightarrow \sup_{\mu \in \mathcal{P}} \Delta(Y, \mu) \geq \inf_{\substack{Y \subseteq X \\ \dim Y = n}} \sup_{\mu \in \mathcal{P}} \|u(\mu) - P_Y u(\mu)\| = d_n(\mathcal{M})$$

\Rightarrow Falls $\Phi_{GRE,n}$ gut, muss $d_n(\mathcal{M})$ klein sein. Falls $d_n(\mathcal{M})$ nicht klein, kann $\Phi_{GRE,n}$ keine gute Approximation liefern.

- Spannend ist umgekehrte Frage, ob abfallendes d_n auch hinreichend für Gelingen des Greedy-Verfahrens.
- Antwort auf diese Fragen wurden in letzten Jahren gegeben:
 (BMPPT 2012): Buffa, Maday, Patera, Prud'homme, Turinici: A-priori convergence of the greedy algorithm for the parameterized reduced basis method
 M2AN, 46:595-..., 2012
 (BCDDPW): Binev, Cohen, Dahmen, DeVore, Petrova, Wojtaszczyk: Convergence Rates for Greedy Algorithms in Reduced Basis Methods
 SIAM J. Math. Anal., 43(3), 1455..., 2011.
- Die Hoffnung, ein Ergebnis der Form $\epsilon_n \leq cd_1(\mathcal{M})$ zu erhalten kann (ohne weitere Annahme) leider nicht erreicht werden. Dies sieht man durch Vergleich von

$$\bar{d}_n(\mathcal{M}) = \inf_{\substack{Y \subseteq \text{span}(\mathcal{M}) \\ \dim Y = n}} d(Y, \mathcal{M}) \quad \text{und} \quad d_n(\mathcal{M})$$

Theorem 4.1 in (BCDDPW2011) besagt:

- i) Für jedes \mathcal{M} und $n \geq 0$ gilt $\bar{d}_n(\mathcal{M}) \leq (n+1)d_n(\mathcal{M})$

ii) Für jedes $n > 0$ und $\epsilon > 0$ existiert \mathcal{M} , s. d.

$$\bar{d}_n(\mathcal{M}) \geq (n - 1 - \epsilon)d_n(\mathcal{M})$$

Wegen $\epsilon_n \geq \bar{d}_n(\mathcal{M})$ und ii) ist “direkter Vergleich” von ϵ_n und $d_n(\mathcal{M})$ mit C unabhängig von n nicht möglich.

- Lösung ist zusätzliche Annahmen von Raten des Abfalls von d_n , damit können ähnliche Abfallraten für ϵ_n gezeigt werden, z. B. zeigen (BMPPT2012):

Für $S_{train} = \mathcal{P}$ und $\Delta(Y, \mu) = \|u(\mu) - P_Y u(\mu)\|$:

$$\epsilon_n \leq 2^{n+1}(n+1)d_n(\mathcal{M})$$

Falls d_n schnell genug abfällt (z. B. exponentiell $d_n(\mathcal{M}) \leq C \cdot e^{-\alpha n}$) so folgt dann auch exponentieller Abfall von ϵ_n (mit anderem α)

- Ein verbessertes Ergebnis (ohne Faktor $(n+1)$) und ein Ergebnis für Fall algebraischer (polynomiell in N^{-1}) Konvergenz liefert (BCDPW), welches wir in unserer Notation formulieren (ohne Beweis).

Satz 3.56 (Greedy Konvergenzraten)

Sei $S_{train} = \mathcal{P}$ kompakt und $\Delta(Y, \mu)$ so gewählt, dass ex. ein $\gamma \in (0, 1]$ mit

$$\|u(\mu^{(n+1)}) - P_{X_n} u(\mu^{(n+1)})\| \geq \gamma \sup_{u \in \mathcal{M}} \|u - P_{X_n} u\| \quad (3.24)$$

- i) (algebraische Konvergenz) Falls $d_n(\mathcal{M}) \leq M \cdot n^{-\alpha}$ für geeignetes α , $M > 0$ und alle $n \in \mathbb{N}$ und $d_0(\mathcal{M}) \leq M$ dann gilt

$$\epsilon_n \leq C \cdot M n^{-\alpha}, \quad n > 0$$

mit explizit berechenbarer Konstante C .

- ii) (exponentielle Konvergenz) Falls $d_n(\mathcal{M}) \leq M \cdot e^{-an^\alpha}$ für $n \geq 0$, $M, a, \alpha > 0$ dann gilt

$$\epsilon_n \leq C M e^{-cn^\beta}, \quad n \geq 0$$

mit $\beta := \frac{\alpha}{\alpha+1}$ und geeignete Konstanten $C, c > 0$.

Bemerkung. “Quasi-Optimalität des Greedy-Verfahrens: bis auf Konstante so gut wie optimale Approximation.

Bemerkung (“strong” vs “weak” greedy).

- Für $\gamma = 1$ nennt man das Verfahren “strong greedy”. Wird nur durch die Wahl

$$\Delta(Y, \mu) := \|u(\mu) - P_Y u(\mu)\|$$

realisiert.

- Für $\gamma < 1$ nennt man das Verfahren “weak greedy” d.h. statt schlechtest-approximiertes Element wird ein einigermaßen schlecht approximiertes Element gewählt zur Basisgenerierung.
- Achtung $\gamma \neq \gamma(\mu)$ Stetigkeitskonstante

Interessant ist Frage, ob Verwendung von Fehlerschätzern Bedingung (3.24) erfüllt für geeignetes γ . Für $\Delta(Y, \mu) := \Delta_N(\mu)$ kann dies positiv beantwortet werden.

Satz 3.57 (Δ_N liefert weak Greedy)

Das Greedy-Verfahren mit Fehlerindikator $\Delta(Y, \mu) := \Delta_N(\mu)$ stellt weak greedy Verfahren dar mit Konstante

$$\gamma := \frac{\bar{\alpha}^2}{\bar{\gamma}^2}$$

mit $\bar{\alpha}, \bar{\gamma}$ uniforme untere/obere Schranke für Koerzivitäts-/Stetigkeitskonstante.

Beweis. Lemma von Cea 3.9, Fehlerschranke 3.13 und Effektivitätsschranke 3.16 gelten für alle Räume X_n , $n \geq 1$ also

$$\begin{aligned} \|u(\mu^{(n+1)}) - P_{X_n} u(\mu^{(n+1)})\| &= \inf_{v \in X_n} \|u(\mu^{(n+1)}) - v\| \\ &\geq \frac{\alpha(\mu)}{\gamma(\mu)} \|u(\mu^{(n+1)}) - u_N(\mu^{(n+1)})\| \\ &\stackrel{3.16}{\geq} \frac{\alpha(\mu)}{\gamma(\mu)\eta_N(\mu)} \cdot \Delta_N(\mu^{(n+1)}) \end{aligned}$$

Behauptung folgt mit

$$\frac{\alpha(\mu)}{\gamma(\mu)\eta_N(\mu)} \stackrel{3.16}{\geq} \frac{\alpha(\mu)}{\gamma(\mu)} \frac{\bar{\alpha}}{\bar{\gamma}} \geq \frac{\bar{\alpha}^2}{\bar{\gamma}^2} =: \gamma$$

und

$$\Delta_N(\mu^{(n+1)}) = \sup_{\mu \in \mathcal{P}} \Delta_N(\mu) \stackrel{3.13}{\geq} \sup_{\mu \in \mathcal{P}} \|u(\mu) - u_N(\mu)\| \geq \sup_{\mu \in \mathcal{P}} \|u(\mu) - P_{X_n} u(\mu)\|$$

□

Bemerkung.

- Für thermischen Block $B_1 = 2$, $B_2 = 1$ gesehen: d_n fällt exponentiell d.h. hier liefert Greedy-Verfahren exponentielle Konvergenz.
- “Lücke” zwischen Theorie & Praxis ist jedoch noch, dass $S_{train} \neq \mathcal{P}$ weil nur endliche Mengen S_{train} betrachtet werden können.
- In der Praxis beobachtet man jedoch auch für allgemeines B_1, B_2 und solchen endlichen S_{train} konvergenz.

Numerische Beispiele:

demos_chapter3(5) Illustration von Gram-Schmidt ONB aus `demos_chapter(3)` d.h. $B_1 = B_2 = 3$ und nur μ_1 variiert. φ_1 ist normierter Snapshot, $\varphi_2, \dots, \varphi_8$ weisen stärker werdende Gradienten auf mit lokalen Strukturen um Kanten von Ω_1 .

demos_chapter3(6) $B_1 = B_2 = 2$, $\mu \in \mathcal{P} = [0.5, 2]^4$
Greedy-Basis mit zufälliger Menge S_{train} , $|S_{train}| = 1000$. Fehlerindikator $\Delta(Y, \mu) = \Delta_N(\mu)$, Gram-Schmidt ON in jeder Iteration. Testmenge S_{test} , $|S_{test}| = 100$. Bestimmung von maximalem Testfehler und -Schätzer.
 \Rightarrow schöne exponentielle Konvergenz von

$$\max_{\mu \in S_{test}} \|u(\mu) - u_N(\mu)\| \quad \text{und} \quad \max_{\mu \in S_{test}} \Delta_N(\mu)$$

Schätzer ist sehr nah an echtem Fehler (gute Effektivität).

demos_chapter3(7) Effekt bei steigendem $p = B_1 \cdot B_2$
 $B_1 = B_2 = 2, 3, 4$, $\mu \in \mathcal{P} = [0.5, 2]^p$, Greedy wie in vorigem Beispiel.
(Achtung 10 Minuten Laufzeit)
Illustration des Trainingsfehlers $(\epsilon_n)_{n \geq 1}$
 \Rightarrow Exponentielle Konvergenz, aber schlechtere Exponenten für größere p

Bemerkung (Trainingsmenge-Wahl).

- Die Trainingsmenge sollte möglichst repräsentativ für \mathcal{P} sein, kann aber nicht beliebig groß sein aus Laufzeitgründen. Sollte nicht zu klein gewählt werden, um nicht Overfitting zu bewirken. Sorgfältige Wahl von S_{train} kann also entweder Qualität des RB-Modells oder die Offline-Laufzeit verbessern. Hierzu gibt es einige Ansätze & Modifikationen des Greedy-Verfahrens:
- “Multistage-Greedy”: Wähle sehr große Menge S_{train} , zerlege diese in Sequenz größerer Mengen

$$S_{train}^{(0)} \subset S_{train}^{(1)} \subset \dots \subset S_{train}^{(m)} = S_{train}$$

Erzeuge $\Phi_{GRE}^{(0)}$ aus $S_{train}^{(0)}$, dann erweitere diese Basis durch Greedy-Verfahren auf $S_{train}^{(1)}$, etc. Effekt ist wesentliche Beschleunigung des Greedy-Verfahrens für S_{train} . Die meisten Iterationen werden nur mit kleiner Trainingsmenge durchgeführt (schnell), nur wenige Iterationen für $S_{train}^{(m)}$ erforderlich (teuer).

Ref.: Sen: Reduced-Basis Approximation and A Posteriori Error Estimation for Many-Parameter Heat Conduction Problems, Numerical Heat Transfer, Part B: Fundamentals 54(5): 369-389, 2008.

- Randomisiertes Greedy: Statt fester Menge S_{train} der Größe N_{train} in allen Iterationen, wähle in jeder Iteration eine neue Trainingsmenge der Größe N_{train} . Dadurch

wird praktisch eine Trainingsmenge der Größe $N \cdot N_{train}$ in der Basisgenerierung verwendet.

Ref.: [HSZ2013]: Hesthaven, Stamm, Zhang: Efficient greedy algorithms for high-dimensional parameter spaces with applications to empirical interpolation and reduced basis methods. M2AN, 2013.

- Saturierungs-Annahme (?): Unter Annahme, dass ein Fehlerindikator für ein Parameter sich in einer Sequenz von Basiserweiterungen höchstens um Faktor C_s verschlechtert, besteht folgende Beschleunigungsmöglichkeit:

Für feste Menge S_{train} wird jeder Parameter μ , der im Laufe des Greedy-Verfahrens $\Delta_N(\mu) \leq \frac{\epsilon_{tol}}{C_s}$ erfüllt, markiert und künftige Fehlerschätzer nicht mehr berechnet, da μ bereits präzise erfasst. [HSZ2013] mit weiteren technischen Schnörkeln.

- Adaptive Trainingsmengen-Erweiterung:
Idee: Übertragen des adaptiven FEM-Schemas “Solve, Estimate, Mark, Refine” auf das Parametergebiet:

Initiale Trainingsmenge (grob) $S_{train}^{(0)}$ ist Menge der Knoten eines Gitters auf \mathcal{P} . Auf $S_{train}^{(0)}$ wird ein Greedy-Verfahren mit “early stopping” angewandt, d.h. das Greedy-Verfahren wird abgebrochen, sobald Overfitting detektiert wird, d.h. $\frac{E_{val}}{E_{train}}$ zu groß wird, wobei E_{val} , E_{train} den aktuell maximalen Fehlerindikator über einer Validationsmenge (zufällig) und S_{train} darstellen. Sobald Overfitting detektiert wird, werden für alle Gitterelemente Fehlerindikatoren bestimmt (z.B. Fehlerschätzer im Mittelpunkt), ein Anteil $\Theta \in (0,1]$ der Elemente mit größten Indikatoren zur Verfeinerung markiert, das Parametergebiet verfeinert und seine Knoten ergeben erweiterte Trainingsmenge $S_{train}^{(1)}$. Dies wird wiederholt, bis ϵ_{tol} erreicht wird.

Ergebnis ist gleichverteilter Fehler und sehr problemangepasste Wahl von S_{train} z.B. führt dieser Algorithmus automatisch zu Verfeinerungen in wichtigen Bereichen. Bei Diffusion z.B. in bereichen kleiner Diffusionsparameter.

Ref.: [HDO11] Haasdonk, Dihlmann, Ohlberger: A Training Set and Multiple Basis Generation Approach for Parametrized Model Reduction Based on Adaptive Grids in Parameter Space. MCMDS, 17 : 423-442, 2011.

- Greedy mit Optimierung: Statt großer Menge S_{train} wird kleines S_{train} gewählt. Jedes $\mu \in S_{train}$ wird als Startwert eines Optimierungsproblems gewählt. Aus den N_{train} lokalen Optima wird $\mu^{(n+1)}$ als nächster Snapshotparameter gewählt.

Ref.: Urban, Volkwein, Zeeb: Greedy Sampling using Nonlinear Optimization. Kapitel in: Quarteroni, Rozza: Reduced Order Methods for Modeling and Computational Reduction, Springer MS&A Serie, 2014.